

目次

Module 1. 開發環境：Anaconda、Jupyter 及爬蟲專案實務.....	1
Module 2. 正規表達式（Regular Expression）說明.....	16
Module 3. HTML 基礎與 HTTP 方法.....	23
Module 4. CSS Selector.....	36
Module 5. Chrome Developer Tool.....	43
Module 6. 套件 requests.....	53
Module 7. 套件 Beautiful Soup 4.....	57
Module 8. cookie 用於 requests.....	60
Module 9. 案例：PTT_NBA_看板主頁與內頁.....	61
Module 10. 套件 Selenium（一）.....	65
Module 11. 套件 Selenium（二）.....	68
Module 12. 套件 Selenium（三）.....	74
Module 13. ActionChains.....	80
Module 14. PyAutoGUI.....	90

- GitHub 專案連結

https://github.com/telunyang/python_web_scraping

- YouTube 頻道

<https://www.youtube.com/@darreninfo-boatman>

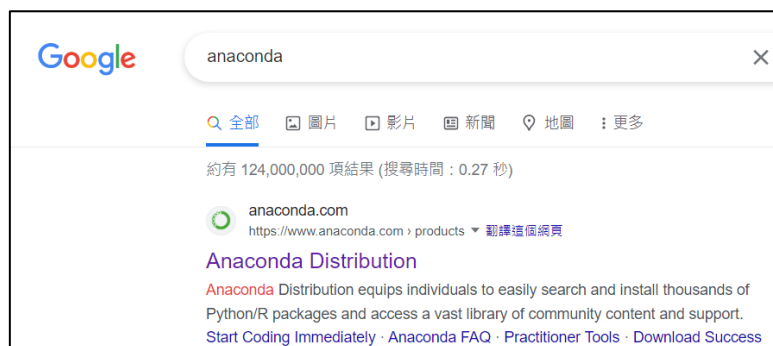
Module 1. 開發環境：Anaconda、Jupyter 及爬蟲專案實務

安裝 Anaconda

參考連結

[1] Anaconda - Individual Edition

<https://www.anaconda.com/products/individual>



圖：可以先至 google 檢索「anaconda」，找到 Anaconda Distribution 的連結



圖：在 Windows 選項下，選擇 64-Bit Graphical Installer，並下載下來



Anaconda3-202
2.10-Windows-x
86_64.exe

圖: 下載後，快速點兩下進行安裝

有安全性警告，可按下執行或同意

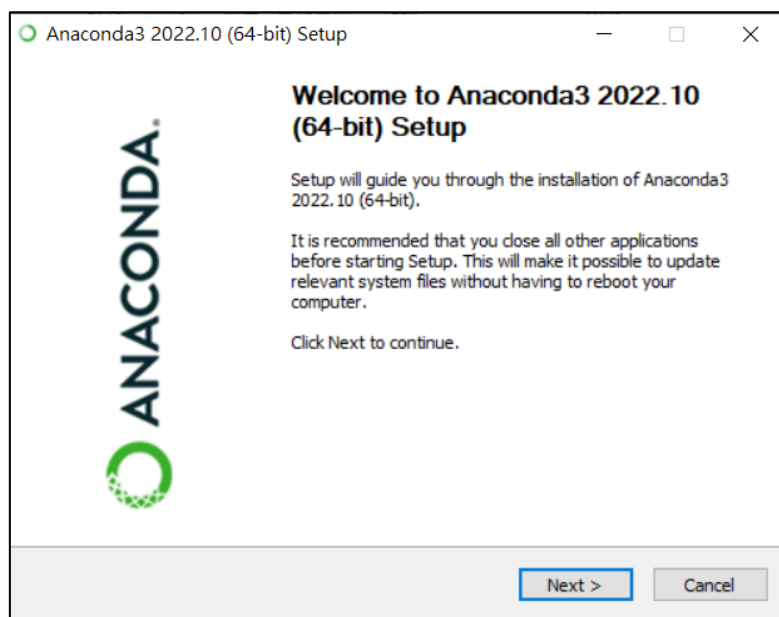
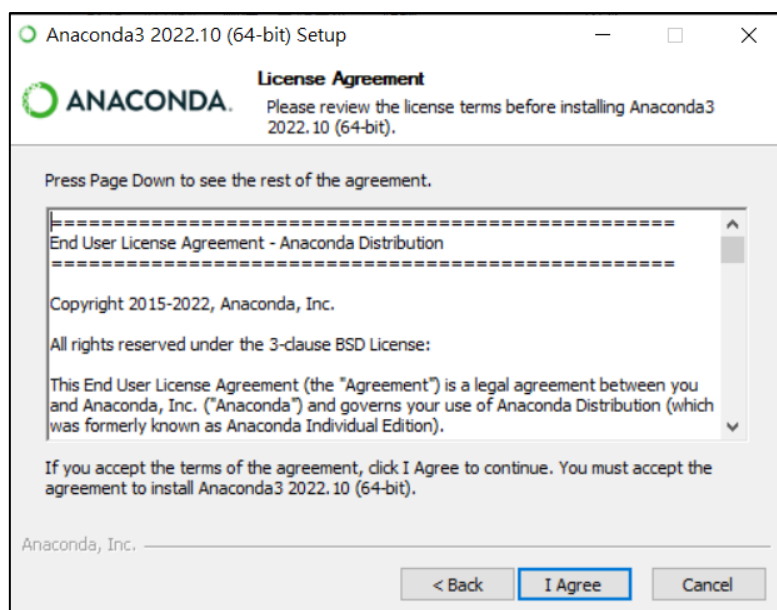
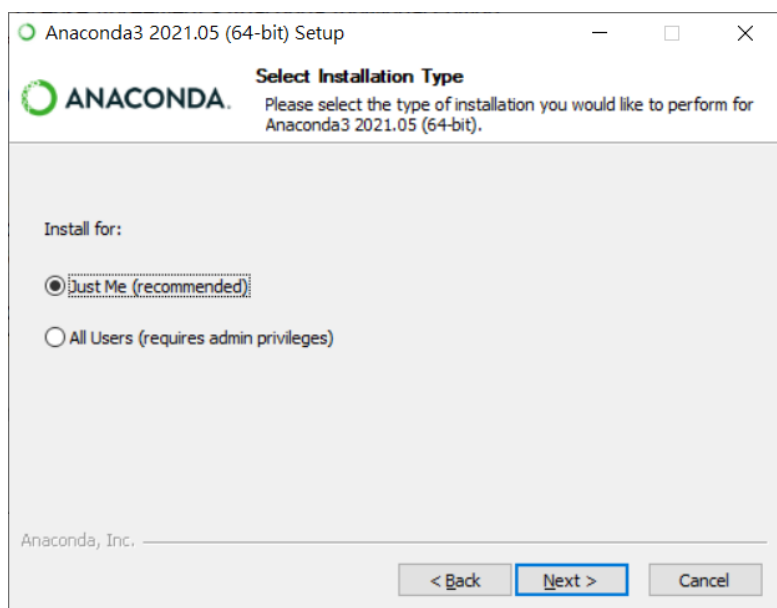


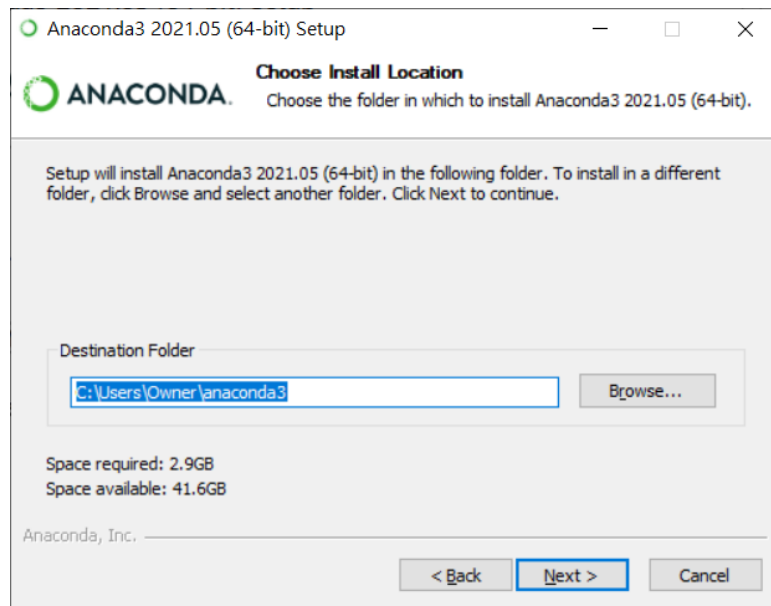
圖: 按下「Next」



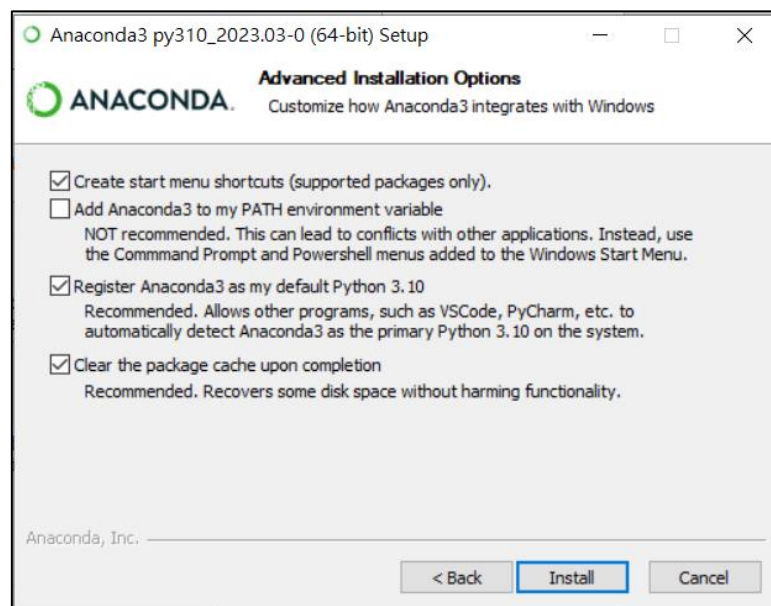
圖：按下「I Agree」



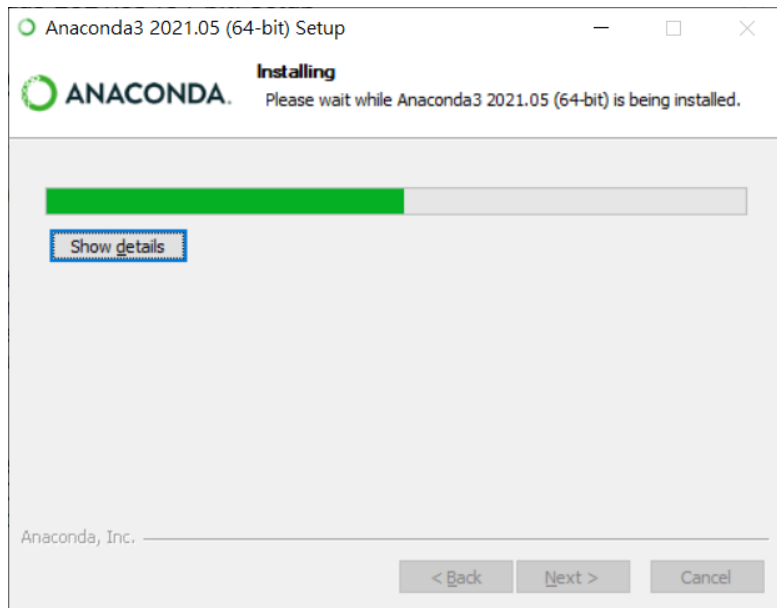
圖：依需求選擇後，按下「Next」




圖：安裝位置會在使用者資料夾中的 anaconda3，依需求設定，按下「Next」



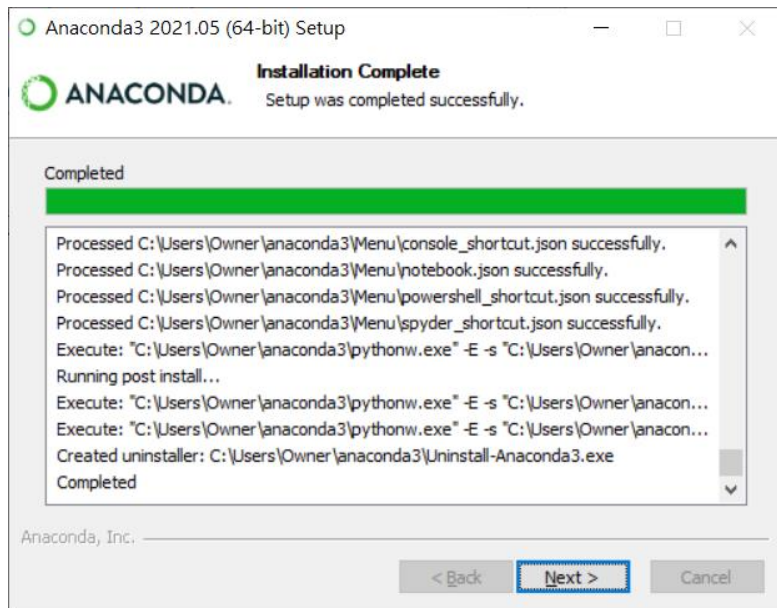
圖：依需求選擇 (最後一個建議打勾，省空間)，按下「Install」，進行安裝



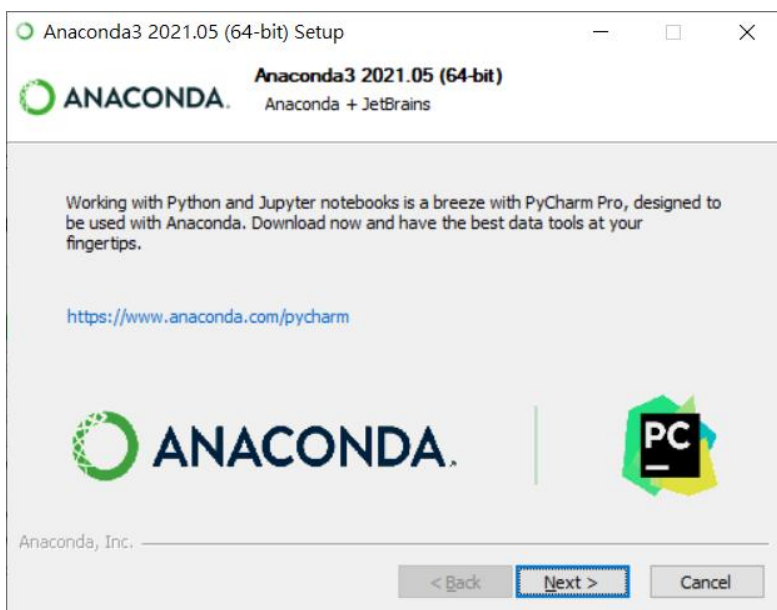
圖：安裝過程，需要一段時間



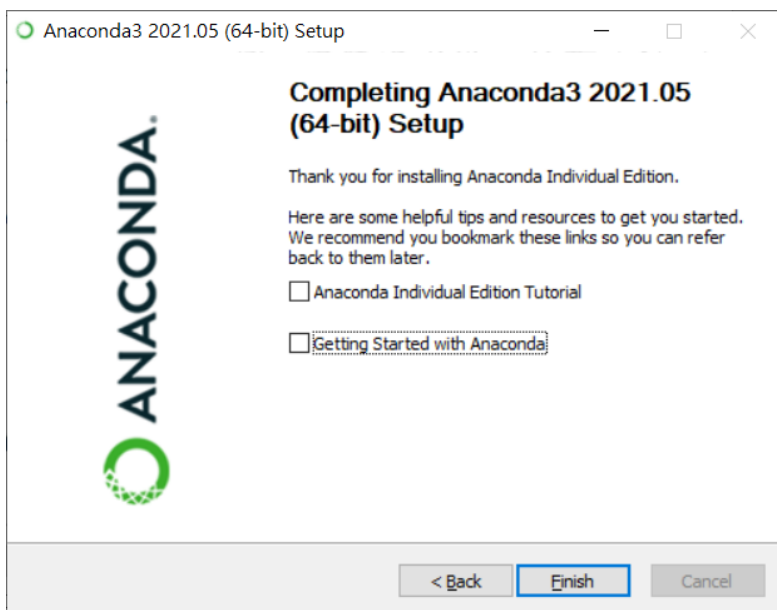
圖：按下「Show details」，會看到安裝過程



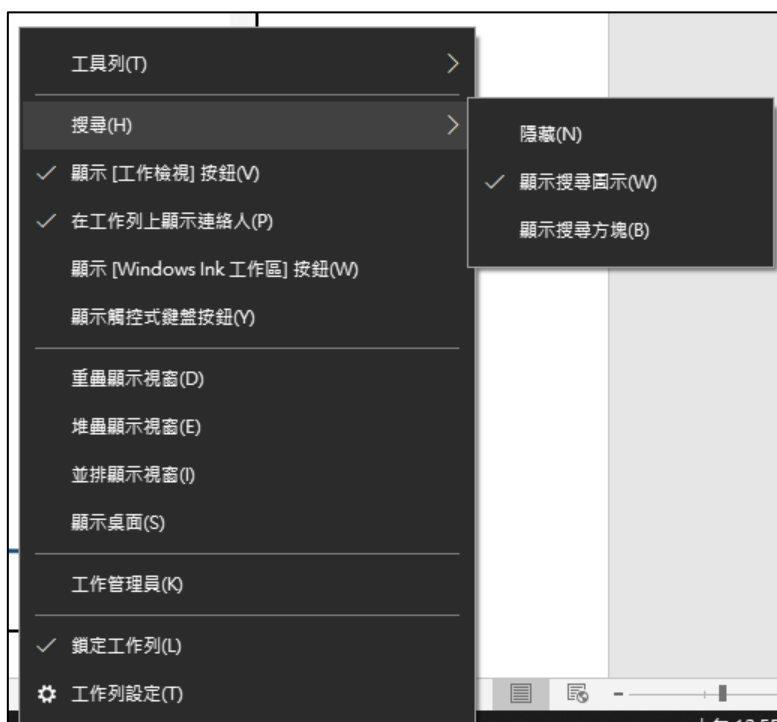
圖：安裝完成後，按下「Next」



圖：按下「Next」



圖：取消勾選圖片中的兩個選項後，按下「Finish」




圖：顯示搜尋圖示



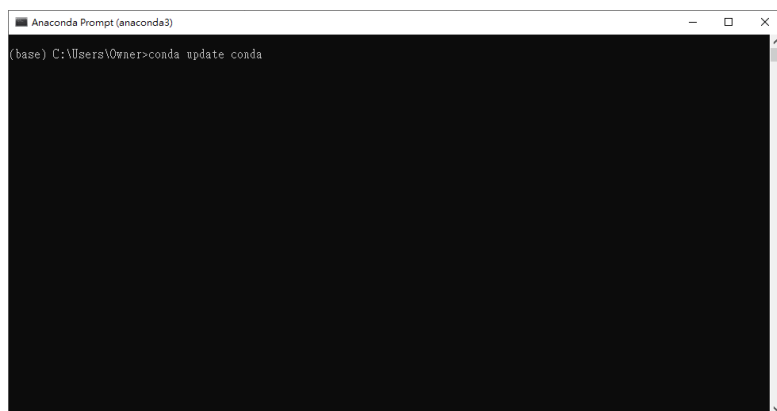
圖：搜尋圖示類似放大鏡，按下搜尋圖示



圖：搜尋「anaconda prompt」，按下「Anaconda Prompt (anaconda3)」



圖：出現 Anaconda Prompt，類似 Windows 的命令提示字元



圖：輸入「conda update conda」，更新 conda 本身

```

Anaconda Prompt (anaconda3)

(base) C:\Users\Owner>conda list
# packages in environment at C:\Users\Owner\anaconda3:
#
# Name                    Version            Build                Channel
#-----
ipywidgets_nb_ext_conf    0.1.0              py37_0
alabaster                  0.7.12            py37_0
anaconda                   2020.02           py37_0
anaconda-client            1.7.2             py37_0
anaconda-navigator         1.9.12            py37_0
anaconda-project           0.8.4             py_0
arviz                       0.26.2            py37_0
asn1crypto                 1.3.0             py37_0
astroid                    2.3.3             py37_0
astropy                    4.0               py37he774522_0
atomicwrites               1.3.0             py37_1
attrs                      19.3.0            py_0
autopep8                   1.4.4             py_0
babel                      2.8.0             py_0
backcall                   0.1.0             py37_0
backports                   1.0               py_2
backports.functools_lru_cache 1.6.1            py_0
backports.shutil_get_terminal_size 1.0.0          py37_2
backports.tempfile         1.0               py_1
backports.weakref          1.0.post1         py_1

```

圖：輸入「conda list」，會顯示目前預設安裝的套件（在虛擬環境 base 下）

```

Anaconda Prompt (anaconda3)

werkzeug                   1.0.0             py_0
wheel                      0.34.2            py37_0
widgetsbextension          3.5.1             py37_0
win_inet_pton              1.1.0             py37_0
win_unicode_console        0.5               py37_0
winecertstore              0.2               py37_0
winpty                     0.4.3             4
wrapit                     1.11.2            py37he774522_0
xlrd                       1.2.0             py37_0
xlswriter                  1.2.7             py_0
xlwings                    0.17.1            py37_0
xlwt                       1.3.0             py37_0
xmltodict                  0.12.0            py_0
xz                         5.2.4             h2fal3f4_4
yaml                       0.1.7             hc54c509_2
yapf                       0.28.0            py_0
zeromq                     4.3.1             h33f27b4_3
zict                       1.0.0             py_0
zipp                       2.2.0             py_0
zlib                      1.2.11            h62dc497_3
zstd                       1.3.7             h508b16e_0

(base) C:\Users\Owner>conda upgrade --all

```

圖：輸入「conda upgrade --all」，更新當前所有套件

```

Anaconda Prompt (anaconda3) - conda upgrade --all

sphinxcontrib-qthelp       1.0.2-py_0 --> 1.0.3-py_0
sphinxcontrib-serializing 1.1.3-py_0 --> 1.1.4-py_0
sphinxcontrib-webside      1.2.0-py_0 --> 1.2.1-py_0
spyder                     4.0.1-py37_0 --> 4.1.3-py37_0
spyder-kernels             1.8.1-py37_0 --> 1.9.1-py37_0
sqlalchemy                 1.3.13-py37he774522_0 --> 1.3.16-py37he774522_0
sqlite                     3.31.1-he774522_0 --> 3.31.1-h2a8f88b_1
torando                    6.0.3-py37he774522_3 --> 6.0.4-py37he774522_1
tqdm                      4.42.1-py_0 --> 4.46.0-py_0
wcwidth                   0.1.8-py_0 --> 0.1.9-py_0
werkzeug                  1.0.0-py_0 --> 1.0.1-py_0
xlswriter                  1.2.7-py_0 --> 1.2.8-py_0
xlwings                    0.17.1-py37_0 --> 0.19.0-py37_0
xz                         5.2.4-h2fal3f4_4 --> 5.2.5-h62dc497_0
zict                       1.0.0-py_0 --> 2.0.0-py_0
zipp                      2.2.0-py_0 --> 3.1.0-py_0
zlib                      1.2.11-h62dc497_3 --> 1.2.11-h62dc497_4

The following packages will be DOWNGRADED:
anaconda                    2020.02-py37_0 --> custom-py37_1
lzo                        2.10-h6df0209_2 --> 2.10-he774522_2

Proceed ([y]/n)? y

```

圖：按下「y」後，再按鍵盤「Enter」

```

Anaconda Prompt (anaconda3) - conda upgrade --all

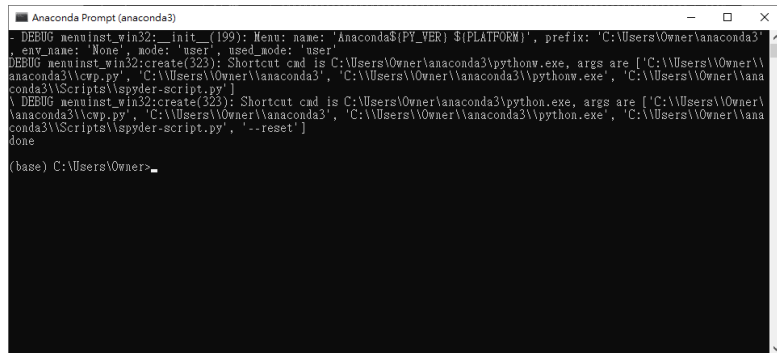
lzo                        2.10-h6df0209_2 --> 2.10-he774522_2

Proceed ([y]/n)? y

Downloading and Extracting Packages
kiwisolver-1.2.0          | 55 KB | ##### 100%
seaborn-0.10.1           | 163 KB | ##### 100%
dash-2.16.0              | 14 KB | ##### 100%
jupyter-core-4.6.3       | 85 KB | ##### 100%
conda-4.8.3              | 2.8 MB | ##### 100%
cython-0.29.17           | 1.8 MB | ##### 100%
prompt-toolkit-3.0.4     | 11 KB | ##### 100%
isspec-0.7.1             | 36 KB | ##### 100%
requests-2.23.0          | 93 KB | ##### 100%
sphinxcontrib-applehelp | 27 KB | ##### 100%
typed-ast-1.4.1          | 141 KB | ##### 100%
curl-7.69.1              | 126 KB | ##### 100%
python-libarchive-c-2.9 | 46 KB | ##### 100%
anaconda_depends-20      | 6 KB | ##### 100%
python-language-server  | 94 KB | ##### 100%
qtawesome-0.7.0          | 726 KB | ##### 100%
spyder-kernels-1.9.1     | 96 KB | ##### 100%
sqlalchemy-1.3.16        | 1.5 MB | 0%

```

圖：更新套件中

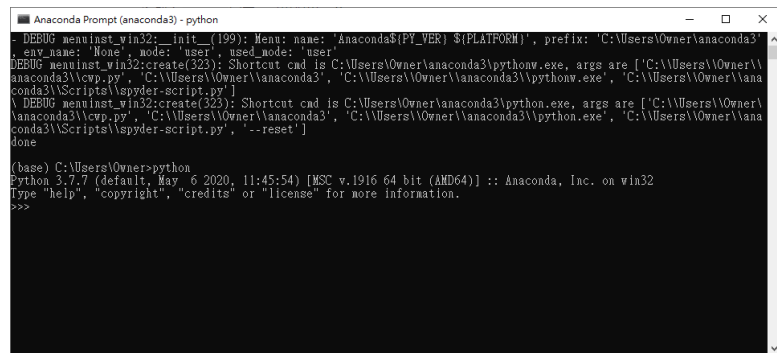


```

Anaconda Prompt (anaconda3)
DEBUG menuinst_win32: __init__(199): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}', prefix: 'C:\Users\Owner\anaconda3'
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\pythonw.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\pythonw.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py']
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\python.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\python.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py', '--reset']
done
(base) C:\Users\Owner>

```

圖：套件更新完成

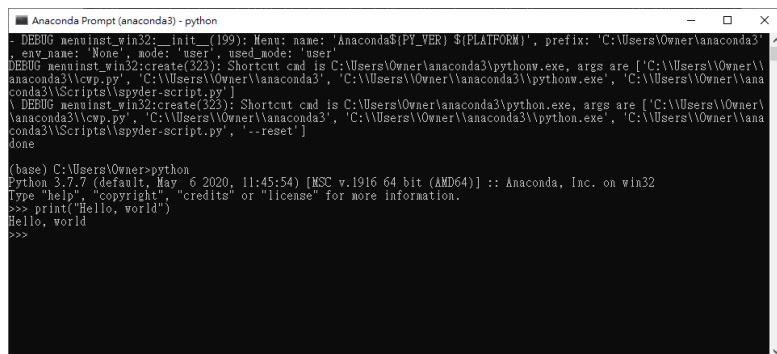


```

Anaconda Prompt (anaconda3) - python
DEBUG menuinst_win32: __init__(199): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}', prefix: 'C:\Users\Owner\anaconda3'
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\pythonw.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\pythonw.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py']
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\python.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\python.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py', '--reset']
done
(base) C:\Users\Owner>python
Python 3.7.7 (default, May 6 2020, 11:45:54) [MSC v.1916 64 bit (AMD64)] :: Anaconda, Inc. on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>>

```

圖：輸入「python」，進入 python 執行環境



```

Anaconda Prompt (anaconda3) - python
DEBUG menuinst_win32: __init__(199): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}', prefix: 'C:\Users\Owner\anaconda3'
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\pythonw.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\pythonw.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py']
DEBUG menuinst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\python.exe, args are ['C:\Users\Owner\anaconda3\Scripts\spyder-script.py', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\python.exe', 'C:\Users\Owner\anaconda3\Scripts\spyder-script.py', '--reset']
done
(base) C:\Users\Owner>python
Python 3.7.7 (default, May 6 2020, 11:45:54) [MSC v.1916 64 bit (AMD64)] :: Anaconda, Inc. on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> print("Hello, world")
Hello, world
>>>

```

圖：輸入「print("Hello, world")」，輸出「Hello, world」，python 安裝成功

```

Anaconda Prompt (anaconda3)
- DEBUG menulst_win32: _init_(199): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}', prefix: 'C:\Users\Owner\anaconda3'
- env_name: 'None', mode: 'user', used_mode: 'user'
- DEBUG menulst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\pythonw.exe, args are ['C:\Users\Owner\anaconda3\Scripts\ipykernel', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\pythonw.exe', 'C:\Users\Owner\anaconda3\Scripts\ipykernel-script.py']
- DEBUG menulst_win32:create(323): Shortcut cmd is C:\Users\Owner\anaconda3\pythonw.exe, args are ['C:\Users\Owner\anaconda3\Scripts\ipykernel', 'C:\Users\Owner\anaconda3', 'C:\Users\Owner\anaconda3\pythonw.exe', 'C:\Users\Owner\anaconda3\Scripts\ipykernel-script.py', '--reset']
done

(base) C:\Users\Owner>python
Python 3.7.7 (default, May 6 2020, 11:45:54) [MSC v.1916 64 bit (AMD64)] :: Anaconda, Inc. on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> print("Hello, world")
Hello, world
>>> exit()

(base) C:\Users\Owner>
```

圖：按下「exit()」回到指令輸入的環境

安裝、切換與刪除 Conda 環境 (Environment)

預設是 (base)，如果有切換環境的需求，例如手上處理著不同 Python 版本和其它相關套件的專案，需要不時切換版本來開發，此時可以建立一到多個 Conda 環境，需要的時候可以切換，不需要的時候可以刪除。

在執行以下的指令前，需要確認目前是否在 Anaconda Prompt 當中，或是支援 Conda 的 Terminal 環境。終端機顯示預設路徑時，最前面會有 (base)，代表目前正在預設的 Conda 環境當中。

安裝 conda 環境

```
conda create --name web_scraping python=3.10 notebook ipykernel
```

進入 conda 環境

```
conda activate web_scraping
```

新增 Kernel

```
python -m ipykernel install --user --name ws --display-name "Python3@ws"
```

註:

1. `python -m` 指的是直接使用模組 (module) 的預設功能。
2. `--user` 代表將 kernel 安裝在個人使用者目錄 (或是個人的家目錄) 當中，而非預設的系統環境。
3. `--name ws` 與 `conda env` 的 `web_scraping` 沒有直接關係，僅是 kernel 在系統當中的別名。
4. `--display-name "Python3@ws"` 是新增 Jupyter Notebook 時的選項。

檢視 Jupyter Notebook kernel

<code>jupyter kernelspec list</code>

刪除 Kernel

<code>jupyter kernelspec uninstall ws</code>
--

注意：

- Jupyter Notebook 建立的 kernel，跟 conda 的 env 概念是不一樣的。
 - Kernel 會啟動網頁版本的線上編輯器，並且使用目前 conda env 的 Python 版本；而 conda 的 env 單純是環境和套件的管理器。
 - 例如在 `python=3.10` 的 conda env 裡面安裝 kernel，此時該 kernel 用的 python 版本就會是 3.10。
 - 無論在任何 conda env 下，只要啟動 Jupyter Notebook，就會以當下目錄作為主目錄/工作路徑。

執行 Jupyter Notebook (在虛擬環境 <code>web_scraping</code> 下)

<code>conda activate web_scraping</code>
--

<code>jupyter notebook</code>

刪除 Conda 環境

<code>conda remove -n web_scraping --all</code>

下載 Chrome Web Driver

1. 請先下載 ChromeDriver (註: 電腦要先安裝 Google Chrome 瀏覽器)

<https://chromedriver.chromium.org/>

2. 請確認目前你電腦裡面的 chrome 瀏覽器版本



圖: 按下瀏覽器右上方的「⋮」→說明→關於 Google Chrome



圖: 請與下載的 ChromeDriver 版本一致

3. 下載 ChromeDriver 檔案，並放到專案資料夾當中




圖: 下載合適的 Chrome 版本




圖: Windows 選擇 win32 ; MacOS 選擇對應的晶片版本

安裝課程所需套件

可以考慮先切換到自訂的 Conda 環境，例如 web_scraping，再透過 pip 安裝套件。

說明

本課程需要安裝的套件指令

```
pip install beautifulsoup4 lxml requests selenium webdriver-manager fake-useragent tika  
pyautogui opencv-python opencv-contrib-python keyboard wget
```

爬蟲專案開發實務分享

1. 個人 YouTube 頻道 (不定時更新)

<https://www.youtube.com/@darreninfo-boatman>

2. 「觀察」是爬蟲工作者的重要技能，HTML & CSS selector 的概念要非常

熟練；有些人習慣使用 XPATH，由於課程時間安排的關係，不會提到。

3. 被對方的伺服器擋住，無法繼續爬取，相換 IP，可以透過

(a)、Amazon Web Service 的 EC2 (虛擬主機)，透過 Running、

Stopped 等過程，提供自動換新的 IP 給我們。

(b)、連接 VPN，例如 Surfshark，透過切換其它網路環境 (俗稱翻牆) 來進行；

(c)、若是人在咖啡廳，臨時被擋，需要換 IP，可以切換到手機網路 (手機

當作無線基地台)，開啟飛航模式，過個幾秒（例如 10 秒後）再閉關

飛航模式，此時網路服務供應商便會提供新的 IP 給我們，便可繼續爬

取資料，有時候可以搭配 PC 平台的手機螢幕控制工具，結合課堂上

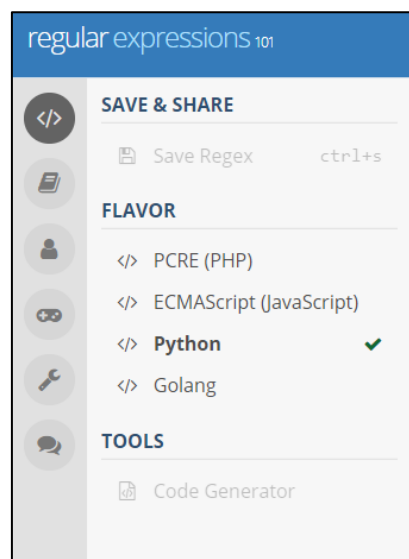
提到的 PyAutoGUI，透過網路請求的品質，來決定是否切換；

(d)、可以整合免費的 **Proxy Pool** 來取得臨時可用的 IP，持續對網頁進行請求，如果更付費的話，品質更好。

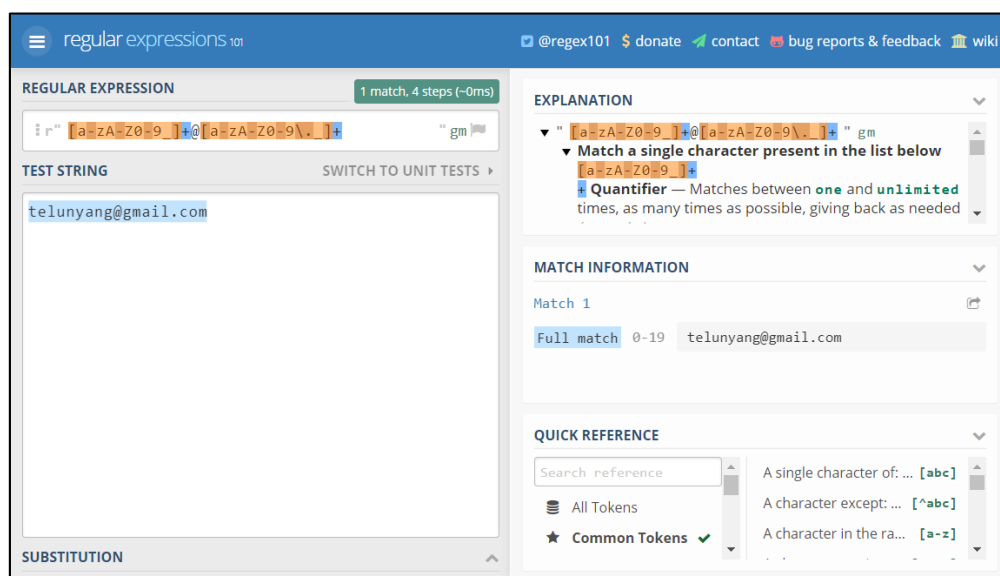
4. 建議：爬取資料時，每經過一個階段（可能是網站換頁前後、網頁動態生成資料之間），各給一個「隨機」的 **sleep 時間**，例如 1 到 3 秒，或是以自身經驗，在攻防之中，取得平衡，設定一組比較不會被擋的隨機數。

Module 2. 正規表達式 (Regular Expression) 說明

正規表達式 (Regular Expression) 是用來配對、過濾、替換文字的一種表示法。請先進入「<https://regex101.com/>」頁面，我們之後測試正規表達式，都會透過這個網頁的功能。正規表達式是需要大量練習才能了解的知識，希望大家都能透過頻繁地練習，慢慢感受到正規表達式在文字處理上的便捷。



圖：選擇 FLAVOR 為 Python



圖：使用正規表達式，來判斷字串是否符合文字格式或條件

下面表格為快速參考的範例：

說明	正規表達式	範例
一個字元: a, b or c	[abc]	abcdef
一個字元，除了: a, b or c	[^abc]	abcdef
一個字元，在某個範圍內: a-z	[a-z]	abcd0123
一個字元，不在某個範圍內: a-z	[^a-z]	abcd0123
一個字元，在某個範圍內: a-z or A-Z	[a-zA-Z]	abcdXYZ0123
避開特殊字元	\ ex. \?	?
任何單一字元	.	任何字元
任何空白字元 (\f\r\n\t\v)	\s	空格、換行、換頁等
任何非空白字元 (不是 \f\r\n\t\v)	\S	非空格、非換行、非換頁等
任何數字	\d	10ab
任何非數字	\D	10ab
任何文字字元	\w	10ab/*AZ^\$
任何非文字字元	\W	10ab/*AZ^\$
以群組的方式配對，同時捕捉被配對的資料	(...) ex. (1[0-9]{3} 20[0-9]{2})	1992, 2019, 1789, 1776, 1024, 3000, 4096, 8192
配對 a 或 b	a b	addbeeeeacccbaa
0 個或 1 個 a	a?	addbeeeeacccbaa
0 個或更多的 a	a*	addbeeeeacccbaa
1 個或更多的 a	a+	aaa, aaaaa
完整 3 個 a	a{3}	aaa, aaaaa
3 個以上的 a	a{3,}	aa, aaa, aaaaa
3 個到 6 個之間的 a	a{3,6}	aaa, aaaaaa, aaaa, aaaaaaaa
字串的開始	^ ex. ^Darren	^DarrenYang
字串的結束	\$ ex. Yang\$	DarrenYang\$
位於文字字元(\w)邊界的字元	\b ex. \bD	DarrenYang
非位於文字字元(\w)邊界的字元	\B ex. \Ba	DarrenYang
配對卻不在群組裡顯示	John (?:Cena)	John Cena

說明	正規表達式	範例
正向環視 (這位置右邊要出現什麼)	John (?=Cena)	John Cena
正向環視否定 (這位置右邊不能出現什麼)	Johnnie (?!Cena)	Johnnie Walker
反向環視 (這位置左邊要出現什麼)	(?<=Johnnie) Walker	Johnnie Walker
反向環視否定 (這位置左邊不能出現什麼)	(?<!=John) Walker	Johnnie Walker

常用方法

匯入 regex 套件

```
import re
```

search

...

說明

`re.search` 會將整個字串進行搜尋，

但只會比對到第一組，

`match[0]` 是 regex 所代表的整個完整比對的字串，

`match[1]` 是第一組()中的內容，

`match[2]` 是第二組()中的內容...

...

```
regex01 = r'[a-zA-Z]([12])\d{8}'
```

```
string01 = "A123456789, S299888777"
```

```
match01 = re.search(regex01, string01)
```

```
print(match01)
```

```
print(match01[0])
```

```
print(match01[1])
```

...

補充：

`match.group()` 或 `match.group(0)` 是 regex 所代表的整個完整比對的字串，

`match.group(1)` 是第一組()中的內容，

`match.group(2)` 是第二組()中的內容...

...

```
print(match01.group(0))
```

```
print(match01.group(1))
```

```
# findall
```

```
...
```

說明

`re.findall` 會將所有配對到的字串

回傳成一個 `list`

```
...
```

```
regex02 = r'[0-9]+'
```

```
string02 = "0911111111, 0922222222, 0933333333"
```

```
listMatch02 = re.findall(regex02, string02)
```

```
print(listMatch02)
```

```
print(listMatch02[0])
```

```
print(listMatch02[2])
```

```
# finditer
```

```
...
```

說明

`re.finditer` 會將所有配對到的字串

以迭代的方式呈現，若沒有配對到，則回傳 `None`

```
...
```

```
regex03 = r'[0-9]+'
```

```
string03 = "0911111111, 0922222222, 0933333333"
```

```
iterableMatch03 = re.finditer(regex03, string03)
```

```
if iterableMatch03 != None:
```

```
    for match in iterableMatch03:
```

```
        print(match[0])
```

```
# match
```

```
...
```

說明

`re.match` 與 `re.search` 的差別，

在於 `match` 會從字串的「開頭」開始比對，

比對不到，便回傳 `None`

```
...
```

```
regex04 = r'2[0-9]{3}\/[0-1]?[0-9]{1}\/([0-3]?[0-9])'
```

```
string04 = "2022/06/30"
```

```
match04 = re.match(regex04, string04)
```

```
print(match04)
```

```
print(match04[0])
```

```
print(match04[1])
```

```
# split
```

```
...
```

說明

`re.split` 類似 `string.split('separator')`，

只是用正規表達式來作為 `separator`，

並回傳 `list`

```
...
```

```
regex06 = r'\d'
```

```
string06 = "One1Two2Three3Four4"
```

```
listMatch06 = re.split(regex06, string06)
```

```
print(listMatch06)
```

```
# sub
```

```
...
```

說明

`re.sub(regex, replace_string, test_string)`

將 `regex` 所代表的文字，改成 `replace_string`，文字來源是 `test_string`

```
...
```

```
regex07 = r"\D"
```

```
string07 = "5-20 #1314"
```

```
strResult = re.sub(regex07, "", string07)
```

```
print(strResult)
```

環視

名稱	語法	說明
正向環視	(?=)	這位置右邊要出現什麼
正向環視否定	(?!)	這位置右邊不能出現什麼
反向環視	(?<=)	這位置左邊要出現什麼
反向環視否定	(?<!)	這位置左邊不能出現什麼

環視（例如去除中文字旁邊的空白）

```

regex08 = r"\s(?:[a-zA-Z])" # 也可以寫成 r"(?![a-zA-Z])\s"
string08 = "一天一蘋果醫生遠離我。An apple a day keeps the
doctor away."
strResult = re.sub(regex08, '', string08)
print(strResult)

# 環視 (加入千分位)
regex09 = r'(?<=\d)(?=(\d{3})+\b)'
string09 = '1234567890'
strResult = re.sub(regex09, ',', string09)
print(strResult)

```

具名群組

```

'''
補充：
除了 .group(n) 以外，
還可以用 key 來代替 n。
'''

# 身分證字號
regex08 = r'[A-Z](?P<gender>[12])\d{8}'
string08 = "A100000001"
match08 = re.match(regex08, string08)

# 完整配對的文字
print(match08[0])
print(match08.group(0))
print(match08.group())

# 具名(類似 key)所代表的值，也可以用索引代號來取得
print(match08.group('gender'))
print(match08['gender'])
print(match08[1])

```

參考資料

1. Python3 正则表达式

<https://www.runoob.com/python3/python3-reg-expressions.html>

2. 正则表达式-全型英數中文字、常用符號 unicode 對照表

<https://blog.typeart.cc/%E6%AD%A3%E5%89%87%E8%A1%A8%E9%81%94%E5%B%8C%E5%85%A8%E5%9E%8B%E8%8B%B1%E6%95%B8%E4%B8%AD%E6%96%87%E5%AD%97%E3%80%81%E5%B8%B8%E7%94%A8%E7%AC%A6%E8%99%9Funicode%E5%B0%8D%E7%85%A7%E8%A1%A8/>

3. 匹配中文字符的正則表達式： [/\u4e00-/u9fa5]

<https://www.itread01.com/content/1513168876.html>

4. 【Regular Expression】正向環視、反向環視

<https://toyo0103.blogspot.com/2017/01/regular-expression.html>

Module 3. HTML 基礎與 HTTP 方法

HTML 簡介

HTML (Hyper Text Markup Language , 超文字標記語言) 是用來產生 Web 網頁的語言。HTML 裡面的標籤 (tags , 例如 ul 、 li 、 a 、 p 、 div 等 , 以及 HTML5 增加的 section 、 article 、 aside 、 nav 、 footer 等) , 這些標籤會告訴瀏覽器何時顯示、顯示什麼、如何顯示。

建立 HTML 檔案

範例

```
<!DOCTYPE html>
<html>
  <head>
    <meta charset="utf-8" />
    <meta name="viewport" content="width=device-width, initial-scale=1, user-scalable=no" />
    <title>歡迎來到我的家</title>
  </head>
  <body>
    <div id="wrapper">
      <!-- nav 在這裡是網頁上緣導覽列 -->
      <header class="head-info">
        <nav class="nav nav-info">
          <ul class="nav-body">
            <li class="nav-list">
              <a class="center link-custom">首頁</a>
            </li>
            <li class="nav-list">
              <a class="center link-custom">連結 1</a>
            </li>
            <li class="nav-list">
              <a class="center link-custom">連結 2</a>
            </li>
          </ul>
        </nav>
      </header>
    </div>
  </body>
</html>
```



```

        </li>
        <li class="nav-list">
            <a class="center link-custom">連結 3 </a>
        </li>
    </ul>
</nav>
</header>

<!-- aside 在這裡是左側的選單列表 -->
<aside class="menu">
    <ul class="menu-body">
        <li class="menu-list">
            <a class="center">側欄連結 1 </a>
        </li>
        <li class="menu-list">
            <a class="center">側欄連結 2 </a>
        </li>
        <li class="menu-list">
            <a class="center">側欄連結 3 </a>
        </li>
    </ul>
</aside>

<!-- main 是主要顯示內容的區域 -->
<main class="content-container">
    <article class="article-paragraph">
        <section class="episode">
            <h3 class="title">HTML parser 開發不求人 - 第三節</h3>
            <div class="content">
                <p>動態網頁的元素走訪，都需要透過不斷地實作、練習，同時...</p>
            </div>
            <div class="content-more">
                <a class="more-link">More</a>
            </div>
        </section>
        <section class="episode">
            <h3 class="title">HTML parser 開發不求人 - 第二節</h3>

```


```
<div class="content">
    <p>動態網頁的元素走訪，都需要透過不斷地實作、練習，同時...</p>
</div>

<div class="content-more">
    <a class="more-link">More</a>
</div>
</section>

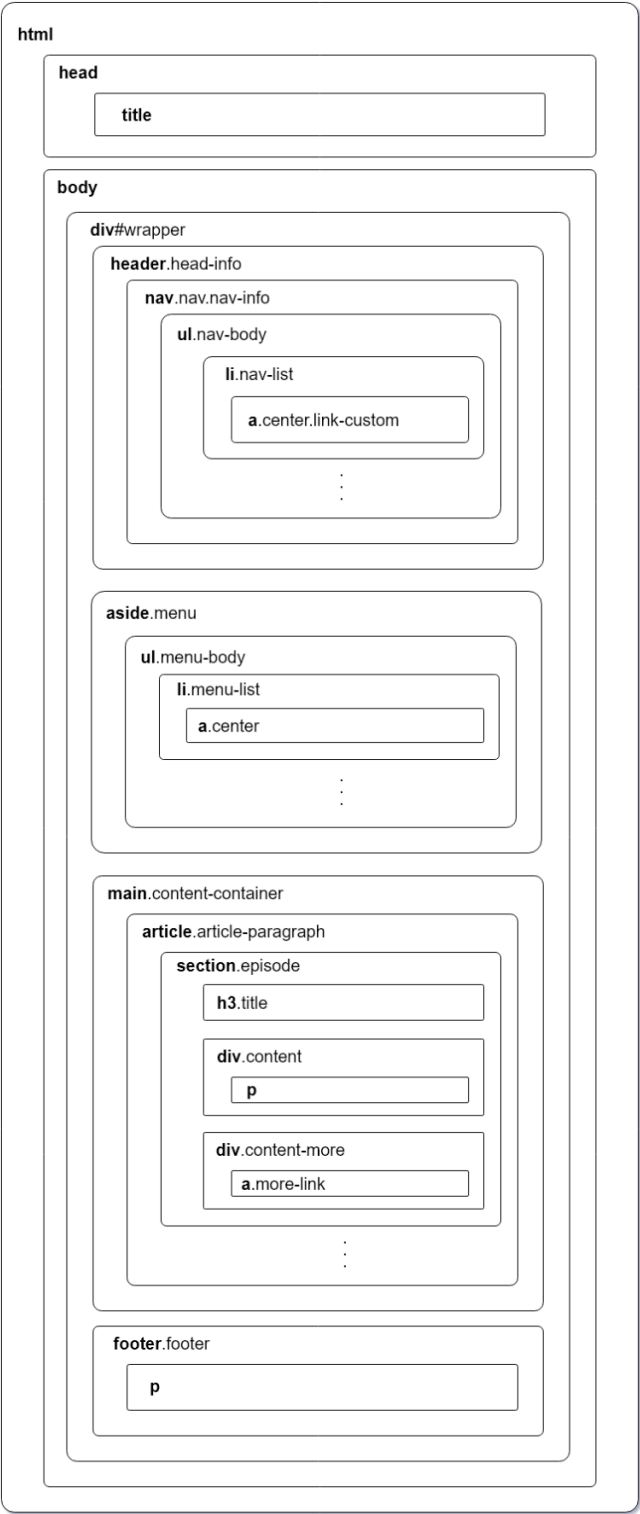
<section class="episode">
    <h3 class="title">HTML parser 開發不求人 - 第一節</h3>
    <div class="content">
        <p>動態網頁的元素走訪，都需要透過不斷地實作、練習，同時...</p>
    </div>
    <div class="content-more">
        <a class="more-link">More</a>
    </div>
</section>
</article>
</main>

<!-- footer 在這裡是簡單提供網站的基礎資訊 -->
<footer class="footer">
    <p>歡迎光臨！本站由 Darren Yang 本人親自虛構...</p>
</footer>
</div>
</body>
</html>
```

基本 HTML 階層，大致上長這個樣子：



若是網頁排版上的設定，應該長這個樣子：



標籤介紹

介紹範例裡頭的標籤。

標籤	範例	說明
<!DOCTYPE>	<!DOCTYPE html> <html> ... </html>	定義文件的格式。
<head>	<head> <title>我的網站 </title> </head>	定義有關這個文件的資訊，至少會與 <title> </title> 一起使用。
<title>	<title>我的網站 </title>	定義文件的標題。
<header>	<header>頁首資訊 </header>	文件的頁首資訊。
<nav>	<nav>導覽列 </nav>	導覽列，定義導覽連結。
	 清單項目 1 清單項目 2 	定義尚未排序的列表。
	 清單項目 1 清單項目 2 	定義一個項目列表。
<!-- ... -->	<!-- 這裡是註解 -->	HTML 文件中的註冊。
<a>	<a>友站連結 	定義超連結。
<main>	<main>放置主要內容 </main>	具體說明文件的主要內容。
<section>	<section>放置需要區隔的資訊 </section>	定義文件的部分內容。
<article>	<article>文章內容 </article>	定義一篇文章。
<aside>	<aside>側欄資料 </aside>	定義在網頁側邊的內容。
<div>	<div>放置需要區隔的資訊 </div>	類似 <section>，定義文件的部分內容。
<h1> 到 <h6>	<h3>某個主題或是需要明顯標註的資訊 </h3>	定義 HTML 的標題/標頭。
<p>	<p>文章當中的段落 </p>	定義文字段落。
<footer>	<footer>頁尾資訊 </footer>	文件的頁尾資訊。

補充說明

網頁當中，也有表格元素，叫作「table」，它的格式通常如下：

```
<table>  
  <thead>
```

```
<tr>
  <th>標題 1</th>
  <th>標題 2</th>
  <th>標題 3</th>
</tr>
</thead>
<tbody>
  <tr>
    <td>第 1 行的第 1 個表格</td>
    <td>第 1 行的第 2 個表格</td>
    <td>第 1 行的第 3 個表格</td>
  </tr>
  <tr>
    <td>第 2 行的第 1 個表格</td>
    <td>第 2 行的第 2 個表格</td>
    <td>第 2 行的第 3 個表格</td>
  </tr>
  <tr>
    <td>第 3 行的第 1 個表格</td>
    <td>第 3 行的第 2 個表格</td>
    <td>第 3 行的第 3 個表格</td>
  </tr>
</tbody>
<tfoot>
  <tr>
    <td>表格尾端第 1 個表格</td>
    <td>表格尾端第 2 個表格</td>
    <td>表格尾端第 3 個表格</td>
  </tr>
</tfoot>
</table>
```

它跟其它元素一樣，可能會有自己的 css 設定，例如 id、class 等。

其它標籤的使用方式，可以參閱 w3school 的介紹：

<https://www.w3schools.com/tags/>

加入超連結

範例

```
<a href="https://www.ntu.edu.tw" target="_blank">國立臺灣大學</a>
```

a 是一種 html tag/element，也可視為一種物件，href 與 target 是 a 的屬性。

自訂屬性

在 HTML 5 的規範下，可以用「**data-***」的格式，來自訂屬性，以便 jQuery 可以透過自訂屬性來取得自訂的資料，例如「**data-item-id='11'**」、「**data-user-name='Darren Yang'**」、「**data-height='1024'**」、「**data-width='768'**」、「**data-what-you-may-call-it='Iron man'**」

範例

```
<a href="https://www.iiiedu.org.tw/" target="_blank" data-item-id="5566" data-user-name="Darren Yang" data-tmp-path="/tmp">資策會數位教育研究所</a>
```

確定屬性後，便能透過元素擷取的套件，來取得屬性資訊。

常見 HTTP 方法介紹

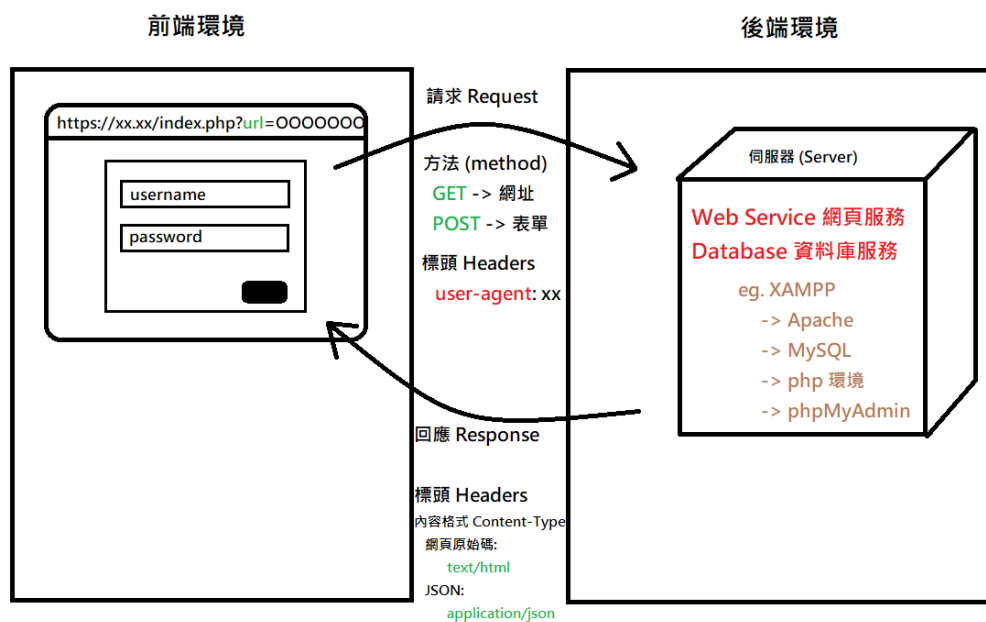
HTTP 請求方法在 RESTful API 中的典型應用				
資源	<u>GET</u>	<u>PUT</u>	<u>POST</u>	<u>DELETE</u>
一組資源的 URI，比如 https://example.com/resources	列出 URI，以及 該資源組中每個 資源的詳細資訊 (後者可選)。	使用給定的一組 資源替換目前整 組資源。	在本組資源中建 立/追加一個新 的資源。該操作 往往返回新資源 的 URL。	刪除整組資源。
單個資源的 URI，比如 https://example.com/resources/142	取得指定的資源 的詳細資訊，格 式可以自選一個 合適的網路媒體 類型 (比如： XML、JSON 等)	替換/建立指定 的資源。並將其 追加到相應的資 源組中。	把指定的資源當 做一個資源組， 並在其下建立/ 追加一個新的元 素，使其隸屬於 目前資源。	刪除指定的元 素。

細說 GET 與 POST 方法

舉個例子，如果 HTTP 代表現在我們現實生活中寄信的機制，那麼信封的撰寫格式就是 HTTP。我們姑且將信封外的內容稱為 http-header，信封內的書信稱為 message-body，那麼 HTTP Method 就是你要告訴郵差的寄信規則。

假設 GET 表示信封內不得裝信件的寄送方式，如同是明信片一樣，你可以把要傳遞的資訊寫在信封(http-header)上，寫滿為止，價格比較便宜；然而 POST 就是信封內有裝信件的寄送方式 (信封有內容物)，不但信封可以寫東西，信封內 (message-body) 還可以置入你想要寄送的資料或檔案，價格較貴。

使用 GET 的時候我們直接將要傳送的資料以 Query String (一種 Key/Value 的編碼方式) 加在我們要寄送的地址(URL)後面，然後交給郵差傳送。使用 POST 的時候則是將寄送地址(URL)寫在信封上，另外將要傳送的資料寫在另一張信紙後，將信紙放到信封裡面，交給郵差傳送。



圖：請求(request)與回應(response)

GET 方法


表單資料將以字串方式附加在網址 (URI) 的後面傳送，在網址尾端，會以「？」符號，開啟跟著表單中的資料，每個欄位間的值，以「&」連接起來。

一般來說，GET 參數 (Query String) 的格式如下：


`https://www.104.com.tw/jobs/search/?ro=1&kwop=7&keyword=python&order=13&asc=0&page=1&mode=s&jobsource=2018indexpoc`

key (鍵)	value (值)
ro	1
kwop	7
keyword	python
order	13
asc	0
page	1
mode	s
jobsource	2018indexpoc

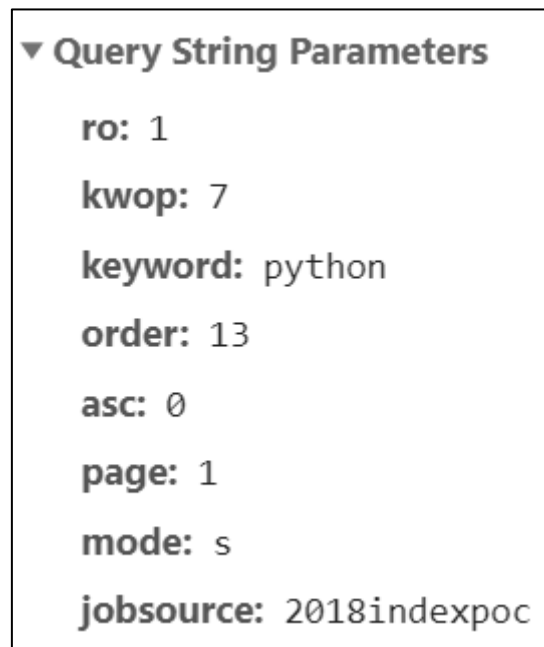
我們將前面的網址放到 **chrome** 瀏覽器的網址列中，讀取結束後，按下 **Ctrl + Shift + i**，再按下 **Network**，然後 **Ctrl + R**，重新讀取網址，再從左側的 **Name** 欄位裡，選擇最上面（通常最先被讀取的那個）的項目，再選 **Headers**，會看到以下的資訊：



圖：選擇第一個項目



圖：看到 Headers 裡面的 General，明確指出 Request Method 是 GET



圖：移到最下面，可以看到 Query String 的參數

POST 方法

我們用網頁表單的格式來說明：

格式

```
<form name = "myForm"
action = "資料處理程式的 URI"
method = "POST"
enctype = "application/x-www-form-urlencoded 或是 multipart/form-data")
>
.....
</form>
```

說明

- **name** 是指 **form** 的名稱，例如：myForm。
- **action** 是指該 **form** 被使用者送出之後，負責接收與處理資料的程式之 **URI** (Uniform Resource Identifiers)。如果省略不寫的話，會以當前所在的 **URI** 來取代。
- **method** 用來規範該 **form** 被送出時，所採用的 **HTTP method**，預設值是 **GET**。
 - **POST** 方法是將資料包裝在 **HTTP** 標頭內 (message-body 當中) 傳送給 web server。
 - 使用 **GET method** 所能傳遞的資料有限 (連同 **URI** 共 255 字元)，在需要上傳大量資料或檔案時，會使用 **POST method**。
- **enctype** 用以規範該 **form** 被送出時，所採用的 **content type**。可用的值有兩種：**application/x-www-form-urlencoded** (預設值) 與 **multipart/form-data**。
 - 當您打算透過表單來上傳檔案時，請務必將 **enctype** 設為 **multipart/form-data**，同時 **method** 也要設為 **POST** 才行。

Module 4. CSS Selector

概述 CSS Selector

CSS selectors 定義了 CSS 規則該套用在哪些網頁元素上，可以粗略分成「標籤(元素)選擇器」、「類別選擇器」、「ID 選擇器」、「屬性選擇器」。

*****：通用選擇器(Universal selector)

將樣式套用於全部元素

```
<style type="text/css">
  * { color: Red; }
</style>
```

element：元素選擇器(Element type selector)

將樣式套用於指定元素

```
<style type="text/css">
  div { color: Red; }
  p { color: Blue; }
</style>

<div> Red </div>
<p> Blue </p>
```

.class：類別選擇器(Class selector)

將樣式套用於具指定類別的元素

```
<style type="text/css">
  .Red { color: Red; }
</style>
```

```
<div class="Red"> Red </div>
<p class="Red"> Red </p>
```

element.class : 元素類別選擇器(Class selector)

當元素 e 具指定類別 class，則套用樣式

```
<style type="text/css">
    div.Red { color: Red;}
</style>

<div class="Red"> Red </div>
<p class="Red"> Black </p>
```

注意：元素 e 和 . 中間不可以有空白字元

#id : ID 選擇器(ID selector)

將樣式套用於具指定 ID 的元素

```
<style type="text/css">
    #Red { color: Red; }
</style>

<div id="Red"> Red </div>
```

element#id : 元素 ID 選擇器(ID selector)

當元素 e 具指定 ID eid，則套用樣式

```
<style type="text/css">
    div#Red { color: Red; }
</style>

<div id="Red"> Red </div>
```

```
<p id="Red"> Black </p>
```

註：元素 e 和 # 中間不可以有空白字元

element1, element2 ,element3,...：群組選擇器(Grouped selector)

對 element1、element2 元素套用相同樣式

```
<style type="text/css">
    div, p { color: Black; }
</style>

<div>Black</div>
<p>Black</p>
```

element element：後代選擇器(Descendant selector)

若元素為 d，且為元素 e 的子元素或子孫元素，則套用樣式

```
<style type="text/css">
    div span { color: Black; }
</style>

<div>
    <span>Black</span>
    <p>
        <span>Black</span>
    </p>
</div>
```

element > element：子元素選擇器(Child selector)

若元素 c 為元素 e 的子元素，則套用樣式

```
<style type="text/css">
    div > span { color: Blue; }
```

```

</style>

<div>
  <span>Blue</span>
  <p>
    <span>Black</span>
  </p>
</div>

```

element1 + element2：相鄰元素選擇器(Adjacent sibling selector)

若元素為 element2，且前面有 element1 元素，則套用樣式

```

<style type="text/css">
  div + p { color: Blue; }
</style>

<div>
  <p>Black</p>
  <div>Black</div>
  <p>Blue</p>
</div>

```

補充說明

選擇器	例子	例子描述
<u>.class</u>	.intro	選擇 class="intro" 的所有元素。

補充說明

選擇器	例子	例子描述
<u>.class1.class2</u>	.name1.name2	選擇 class 屬性中同時有 name1 和 name2 的所有元素。
<u>.class1.class2</u>	.name1 .name2	選擇作為類名 name1 元素後代的所有類名 name2 元素。
<u>#id</u>	#firstname	選擇 id="firstname" 的元素。
<u>*</u>	*	選擇所有元素。
<u>element</u>	p	選擇所有 <p> 元素。
<u>element.class</u>	p.intro	選擇 class="intro" 的所有 <p> 元素。
<u>element,element</u>	div, p	選擇所有 <div> 元素和所有 <p> 元素。

補充說明

選擇器	例子	例子描述
<u>element element</u>	div p	選擇 <div> 元素內的所有 <p> 元素。
<u>element > element</u>	div > p	選擇父元素是 <div> 的所有 <p> 元素。
<u>[attribute]</u>	[target]	選擇帶有 target 屬性的所有元素。
<u>[attribute=value]</u>	[target=_blank]	選擇帶有 target="_blank" 屬性的所有元素。
<u>[attribute~=value]</u>	[title~=flower]	選擇 title 屬性包含單詞 "flower" 的所有元素。
<u>[attribute^=value]</u>	a[href^="https"]	選擇其 href 屬性值以 "https" 開頭的每個 <a> 元素。

補充說明		
選擇器	例子	例子描述
<u>[attribute\$=value]</u>	<code>a[href\$=".pdf"]</code>	選擇其 href 屬性以 ".pdf" 結尾的所有 <a> 元素。

參考資料：

CSS 選擇器參考手冊


https://www.w3school.com.cn/cssref/css_selectors.asp

Module 5. Chrome Developer Tool

各頁籤常用功能簡介 (Elements / Console / Network / ...)

Chrome 開發者工具是內建於 Google Chrome 中的 Web 開發和測試工具

網址：<https://developers.google.com/web/tools/chrome-devtools?hl=zh-tw>



圖：Chrome 開發者工具的說明網頁

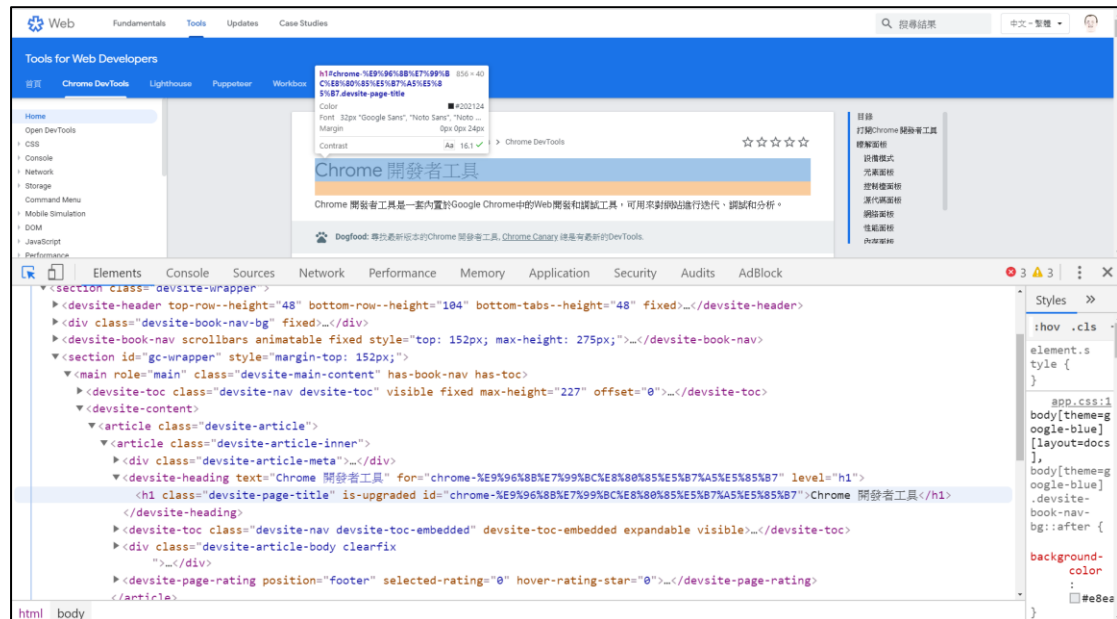
開啟開發工具(dock)

- F12

Elements 面板

檢查 HTML 元素

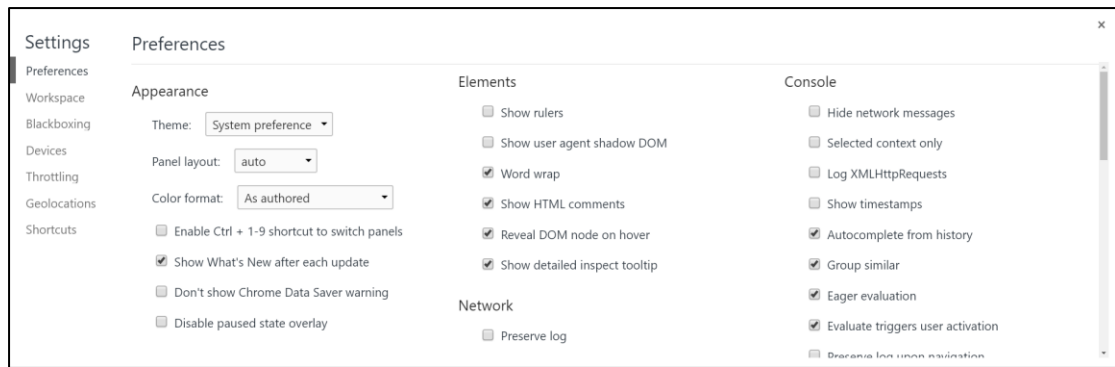
- Ctrl + Shift + C (追縱滑鼠移過網頁元素所在位置的狀態)
- 網頁內容任意處按滑鼠右鍵→檢查



圖：檢查元素

補充說明

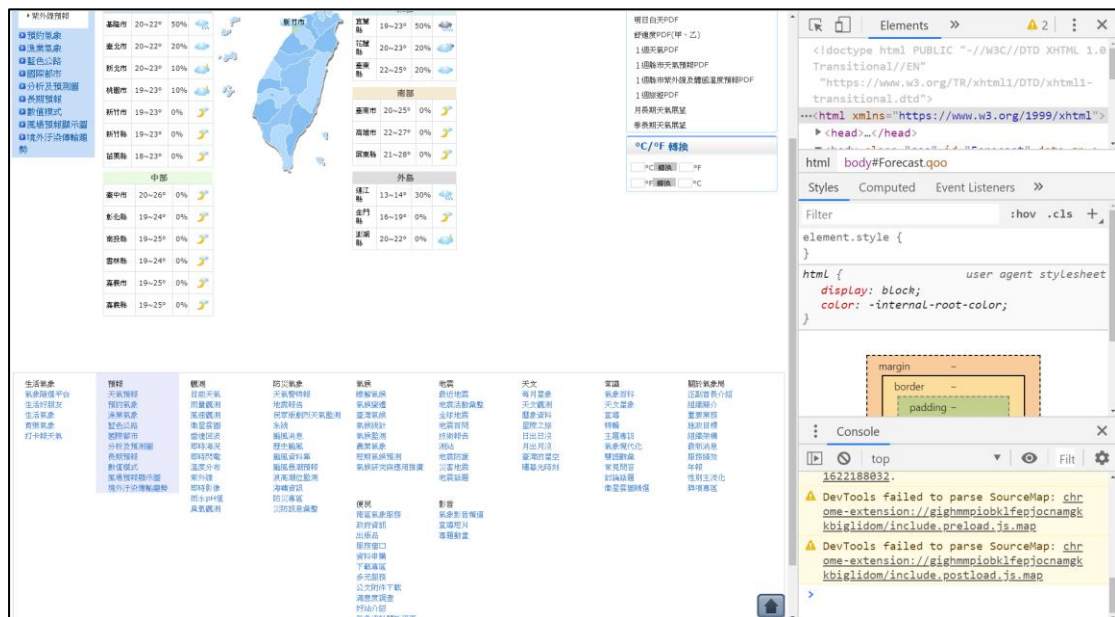
開啟 Chrome 開發者工具以後，按下 F1，可以看到一些偏好設定，方便我們設定開發工具，例如顯示外觀、模擬裝置、自訂地理位置、快捷鍵等。




圖：Chrome 開發者工具偏好設定

開啟開發工具後，常用快速鍵：

- Ctrl + Shift + D 切換檢查元素的 dock side

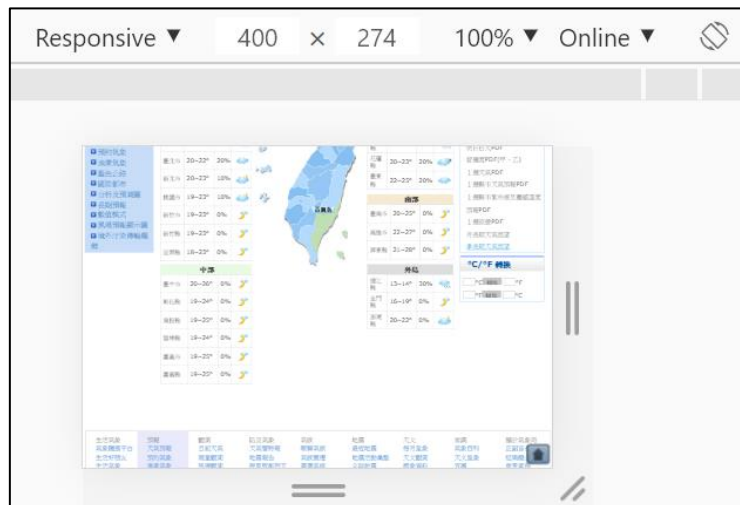


圖：切換 dock side，從下方到右側

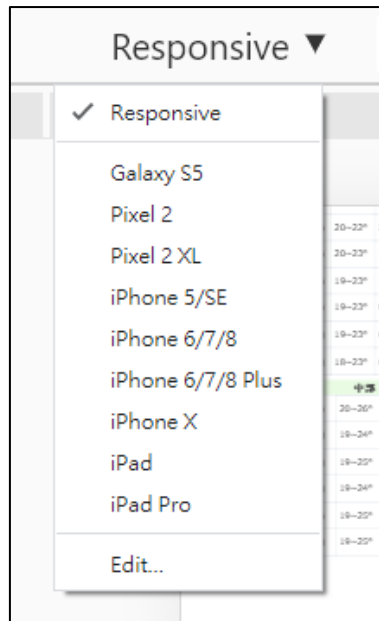


圖：按下三個點的圖示，也可以選擇 dock side

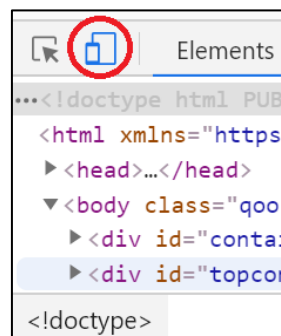
- Ctrl + Shift + M 開啟模擬裝置模式(切換裝置工具欄)



圖：可選擇不用的行動裝置，或自訂寬高，來顯示網頁



圖：選擇裝置來觀看網頁



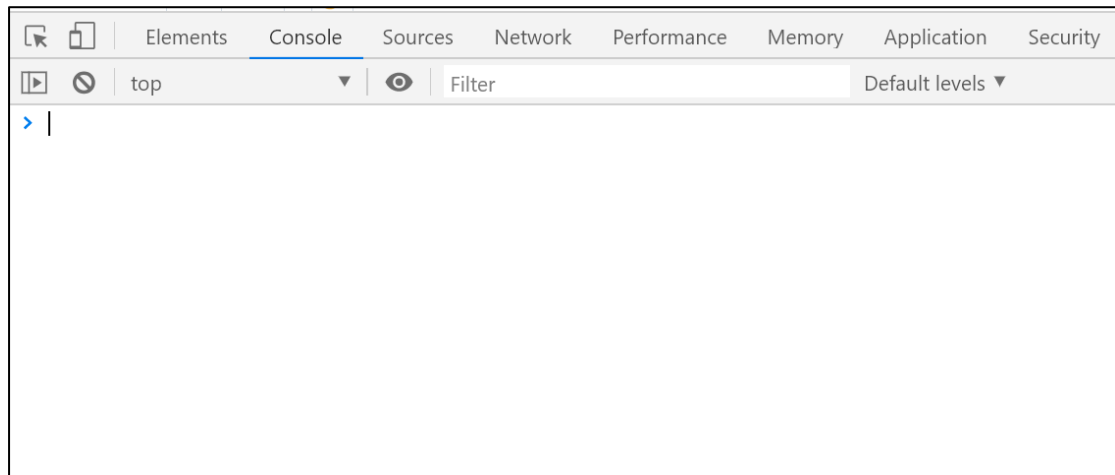
圖：等同按下切換裝置工具欄

- Ctrl + O 尋找 HTML 當中的檔名
- Ctrl + R 或 F5 刷新頁面
- Ctrl + F5 清除快取後，刷新頁面(重新從伺服器端請求下載 HTML)
- Ctrl + L 清除 Console

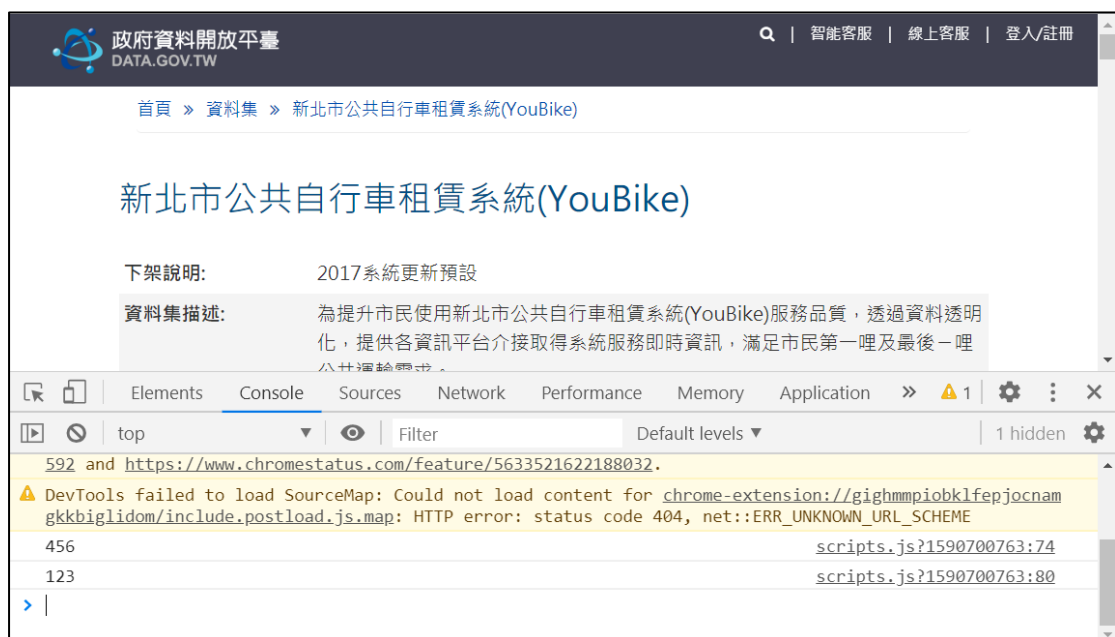
- Shift + Enter 在 Console 中斷行(或多行)

Console 面板

我們可以使用 Console 面板，了解目前網頁執行的狀況。



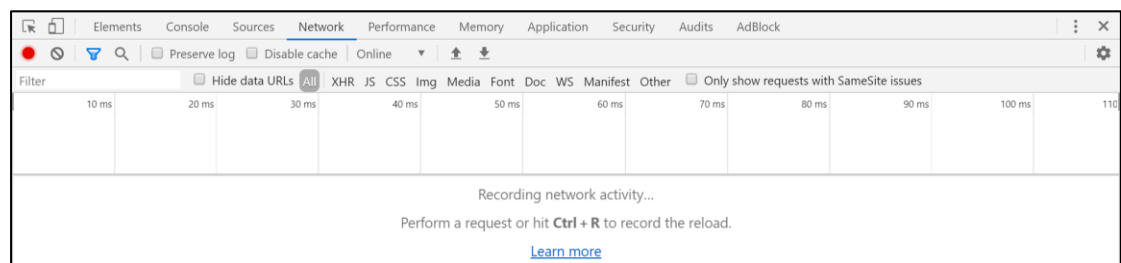
圖：Console 面板



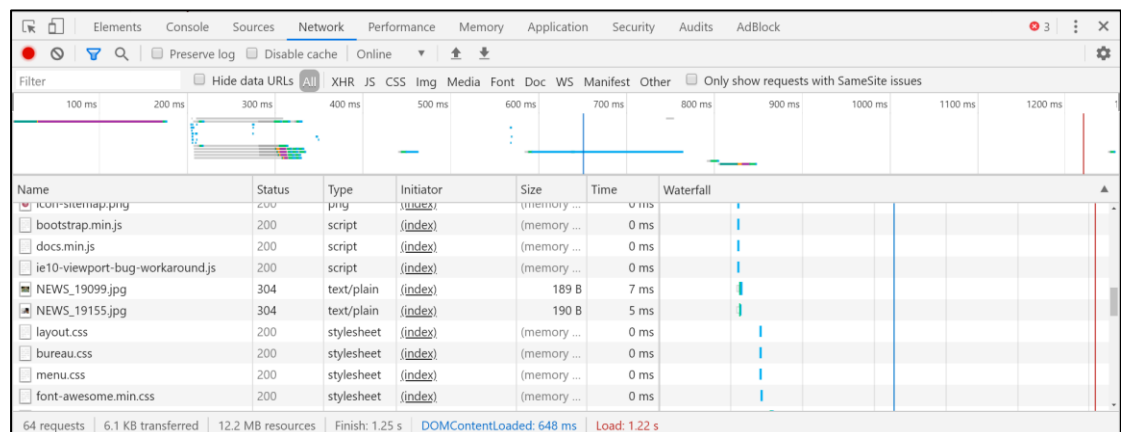
圖：可以看到目前網站的情況。

Network 面板

Network 面板會顯示出所有網路請求的詳細訊息記錄，包括狀態、資源類型、大小、所需時間、HTTP request header 和 response header 等等，明確找出哪些請求比預期還要耗時，並加以調整，是優化網頁的重要工具。



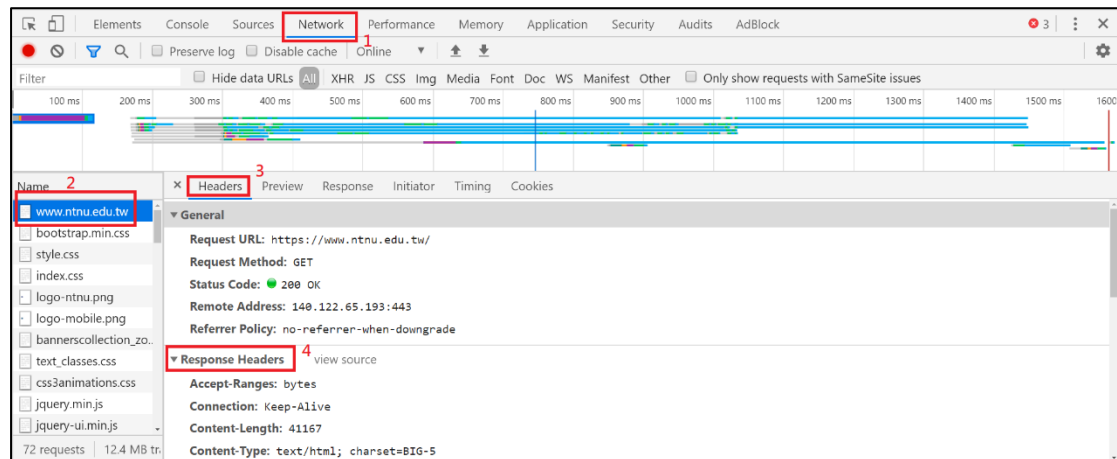
(圖) Network 面板會記錄任何的網路活動



(圖) 記錄網頁讀取的資訊與下載順序

我們可以透過 Headers，來了解網頁請求的狀況。開啟 Headers 的流程為：

1. 開啟 Network 面板
2. Ctrl + R 或是 F5 刷新頁面
3. 點選左側的檔案名稱
4. 點選 Headers



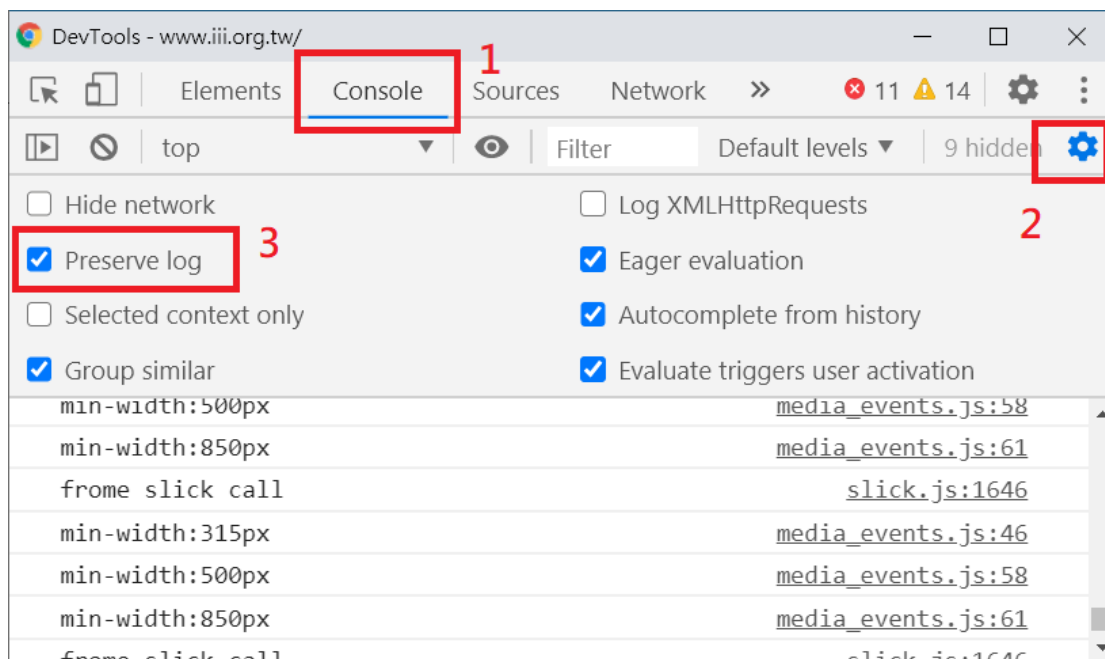
圖：觀看檔案的 Headers 內容

Request Headers (請求標頭 · 參考[維基百科](#))

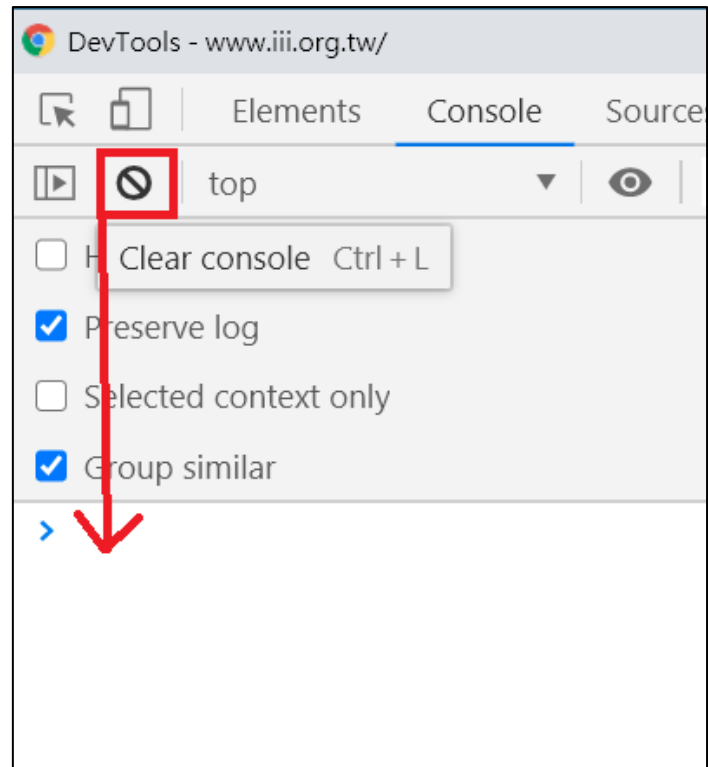
標頭欄位	說明	範例
Cookie	之前由伺服器通過 Set-Cookie 傳送的一個 超文字傳輸協定 Cookie	<div>Cookie:</div> <div>_ga=GA1.3.1322956465.1572335045;loc</div> <div>ale=zh_TW;</div>

標頭欄位	說明	範例
		<div>_gid=GA1.3.1110994946.1584940974;</div> <div>_gat_gtag_UA_141775379_1=1</div>
User-Agent	瀏覽器的瀏覽器身分標識字串	<div>User-Agent: Mozilla/5.0 (X11; Linux</div> <div>x86_64; rv:12.0) Gecko/20100101</div> <div>Firefox/21.0</div>

常用操作流程介紹（ Preserve Log / Clear / ... ）



圖：勾選 Preserve log，縱然頁面刷新，過去的 log 依然會保存起來



圖：按下 Clear Console，或是 Ctrl+L，即可清除 log

Module 6. 套件 requests

<https://httpbin.org/> 是一個專門拿來測試 HTTP Request 的網路服務，只要依照文件發動 HTTP Request 到指定的路徑，就會將它收到的內容以 JSON 格式回傳，在測試 API 行為時非常好用。

HTTP Methods Testing different HTTP verbs		
DELETE	/delete	The request's DELETE parameters.
GET	/get	The request's query parameters.
PATCH	/patch	The request's PATCH parameters.
POST	/post	The request's POST parameters.
PUT	/put	The request's PUT parameters.

圖：支援的 HTTP 方法

Cookies Creates, reads and deletes Cookies		
GET	/cookies	Returns cookie data.
GET	/cookies/delete	Deletes cookie(s) as provided by the query string and redirects to cookie list.
GET	/cookies/set	Sets cookie(s) as provided by the query string and redirects to cookie list.
GET	/cookies/set/{name}/{value}	Sets a cookie and redirects to cookie list.

圖：增刪修 cookies 的操作方法

requests 套件

使用 requests 工具

```
import requests
```

使用 json 工具

```
import json
```

使用 GET 方式下載普通網頁

```
res = requests.get('https://httpbin.org/get')
```

伺服器回應的狀態碼

參考網頁: <https://reurl.cc/2DRpan>

```
print(res.status_code)
```

回傳資料的編碼

```
print(res.encoding)
```

指定回傳資料的編碼

```
# response.encoding = 'utf-8'
```

輸出網頁 HTML 原始碼

```
print(res.text)
```

GET 方法的 query string

```
my_params = {  
    'key1': 'value1',  
    'key2': 'value2'  
}
```

將 query string 加入 GET 請求中

```
res = requests.get('https://httpbin.org/get', params = my_params)
```

觀察 URL

```
print(res.url)
```

```

# 輸出網頁 HTML 原始碼
print(res.text)

# POST 方法的 form data
my_data = {
    'key1': 'value1',
    'key2': 'value2'
}

# 將 form data 加入 POST 請求中
res = requests.post('https://httpbin.org/post', data = my_data)

# 輸出網頁 HTML 原始碼
print(res.text)

# 要上傳的檔案 (變數名稱為 my_filename)
my_files = {
    'my_filename': open('turingcerts.jpg', 'rb')
}

# 將檔案加入 POST 請求中
res = requests.post('https://httpbin.org/post', files = my_files)

# 輸出網頁 HTML 原始碼
print(res.text)

# 自訂標頭
my_headers = {
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/99.0.4844.82
Safari/537.36'
}

# 將自訂標頭加入 GET 請求中
res = requests.get('https://httpbin.org/get', headers = my_headers)

# 輸出網頁 HTML 原始碼
print(res.text)

# 自訂 cookie 格式
my_cookies = {

```



```

    "first_cookie": "hello",
    "second_cookie": "world"
}

# 將 cookie 加入 GET 請求
res = requests.get('https://httpbin.org/get', cookies = my_cookies)

# 輸出網頁 HTML 原始碼
print(res.text)

# 參考網址: https://greenlife.epa.gov.tw/categories/restaurant
# 預設連結 https://greenliving.epa.gov.tw/newPublic/APIs/Restaurant4
# 分頁連結 https://greenliving.epa.gov.tw/newPublic/APIs/Restaurant4/1

# 請求網址
url = 'https://greenliving.epa.gov.tw/newPublic/APIs/Restaurant4/1'
res = requests.get(url)

# 將 json 轉成物件
obj = json.loads(res.text) # 或使用 obj = res.json()

# 輸出對應節點的文字
print(obj['Result'])
print(obj['RowCount'])
print(obj['PageIndex'])

print("=" * 50)

# 輸出部分節點的文字
for o in obj['Detail']:
    if o['Latitude'] == 0.0 or o['Longitude'] == 0.0: continue
    print(f"Id: {o['Id']}")
    print(f"Name: {o['Name']}")
    print(f"Address: {o['Address']}")
    print(f"Latitude: {o['Latitude']}")
    print(f"Longitude: {o['Longitude']}")
    print("=" * 50)

```

Module 7. 套件 BeautifulSoup 4

套件介紹及常用功能

Beautiful Soup 是一個 HTML parser，將 Document 轉換成一個樹狀結構，提供簡單的函式來走訪、搜尋、修改分析此樹狀結構，支援 CSS 選擇器。

常用功能

我們主要用 BeautifulSoup 套件來作為網站解析的工具。

- `find()` 方法 (取得單一元素)
- `find_all()` 方法 (取得元素集合)
- `select_one()` 方法 (取得單一元素)
- `select()` 方法 (取得元素集合)

BeautifulSoup 基本用法

`soup.select()` :

回傳的結果是元素集合 (list 型態, BeautifulSoup ResultSet)

`soup.select_one()` :

回傳的結果是單一元素 (BeautifulSoup Result)

Beautifulsoup 套件

...

[參考網頁](#)

[1] Python 使用 BeautifulSoup 抓取與解析網頁資料，開發網路爬蟲教學
<https://blog.gtwang.org/programming/python-beautiful-soup-module-scrape-web-pages-tutorial/2/>

```
'''

import requests as req
from bs4 import BeautifulSoup as bs
from pprint import pprint

# PTT NBA 板
url = "https://www.ptt.cc/bbs/NBA/index.html"

# 用 requests 的 get 方法把網頁抓下來
res = req.get(url)

# 指定 lxml 作為解析器
soup = bs(res.text, "lxml")
```

```
# 第一個 <a></a>
print(soup.find("a"))

# 全部 <a></a>，此時回傳 list
print(soup.find_all("a"))

# 指定 list 某個元素的 html
print(soup.find_all("a")[2])
```

```
# 取得 id 為 logo 的元素
logo = soup.find(id = "logo")
print(logo)

# 取得所有 div，類別名稱為 r-ent，回傳為 list
posts = soup.find_all("div", class_ = "r-ent")
print(posts)
```

```
'''

以下透過 CSS selector 取得元素，
回傳格式為 list
'''

# 輸出 title
```

```

print(soup.select_one('title'))

# 輸出 a
print(soup.select('a'))

# 透過 class 名稱取得元素
print(soup.select("a.board"))

# 透過 id 名稱取得元素
print(soup.select_one("#logo"))

# 透過 attribute 取得元素
print(soup.select('a[class="board"]'))

# 取得單一節點的文字內容 (select_one 會回傳單一 bs element 物件，select 會回傳 list)
print(soup.select_one('title').get_text())
print(soup.select('a')[0].get_text())

# 透過迭代取得所有 a 的文字內容
for a in soup.select('a'):
    print(a.get_text())

# 透過迭代取得所有 a 的屬性 href
for a in soup.select('a'):
    if a.has_attr('href'):
        print(a['href']) # a.get("href")
    else:
        print("=" * 50)
        print(f"連結[{a.get_text()}] 沒有 href 屬性")
        print("=" * 50)

```

Module 8. cookie 用於 requests

以 PTT Gossiiping (八卦版) 為例

```
import requests as req
from bs4 import BeautifulSoup as bs

# PTT Gossiiping (八卦版)
url = "https://www.ptt.cc/bbs/Gossiping/index.html"

# 首頁網址
prefix = 'https://www.ptt.cc'

# 設定 cookie
my_cookies = {
    "over18": "1"
}

# 用 requests 的 get 方法把網頁抓下來
res = req.get(url, cookies = my_cookies)

# 指定 lxml 作為解析器
soup = bs(res.text, "lxml")

# 顯示連結列表
for a in soup.select('div.r-ent > div.title > a'):
    print(a.get_text())
    print(prefix + a['href'])
```

Module 9. 案例: PTT_NBA_看板主頁與內頁

取得 PTT NBA 列表

匯入套件

```
from bs4 import BeautifulSoup as bs
import requests as req
from pprint import pprint
```

取得新聞列表

```
url = "https://www.ptt.cc/bbs/NBA/index.html"
```

用 requests 的 get 方法把網頁抓下來

```
res = req.get(url)
```

指定 lxml 作為解析器

```
soup = bs(res.text, "lxml")
```

建立 list 來放置列表資訊

```
list_posts = []
```

清空放置列表資訊的變數

```
list_posts.clear()
```

取得 列表 的文字與超連結

```
for a in soup.select('div.r-ent div.title a[href]'):
    print(a.get_text())
    print(a['href']) # 或是 a.get('href')
```

加入列表資訊

```
list_posts.append({
    'title': a.get_text(),
    'link': 'https://www.ptt.cc' + a['href']
})
```

走訪每一個 a link，整合網頁內文

```
for index, obj in enumerate(list_posts):
    res_ = req.get(obj['link'])
    soup_ = bs(res_.text, "lxml")
```

```

# 去掉 div.article-metaline (作者、標題、時間...等)
for div in soup_.select('div[class^="article-metaline"]'):
    div.decompose()

# 去掉 div.push (推文: 推、→、噓) (判斷元素是否存在)
if len( soup_.select('div.push') ) > 0:
    for div in soup_.select('div.push'):
        div.decompose()

# 取得實際需要的內容 (類似 JavaScript 的 innerHTML)
html = soup_.select_one('div#main-content').decode_contents()
# html = str(soup_.select_one('div#main-content')) # 類似
JavaScript outerHTML

# 預覽列表和內文
print(obj['title'])
print(obj['link'])
print(html)
print("=" * 50)

# 整合到列表資訊的變數當中
list_posts[index]['html'] = html

# 預覽所有結果
pprint(list_posts)

```

思考

- 如何取得多個分頁的內容？
 - 觀察分頁數字在網址的呈現方式
 - 將觀察到的分頁數字嵌入對應的網址當中

清空放置列表資訊的變數

```
list_posts.clear()
```

起始頁數

```
init_page = 6503
```

```

# 最新頁數
latest_page = 6504

# 在已經知道分頁數的情況下
for page in range(init_page, latest_page + 1):

    # 取得新聞列表
    url = f"https://www.ptt.cc/bbs/NBA/index{page}.html"

    # 用 requests 的 get 方法把網頁抓下來
    res = req.get(url)

    # 指定 lxml 作為解析器
    soup = bs(res.text, "lxml")

    # 取得 列表 的文字與超連結
    for a in soup.select('div.r-ent div.title a[href]'):
        # 加入列表資訊
        list_posts.append({
            'title': a.get_text(),
            'link': 'https://www.ptt.cc' + a['href']
        })

# 走訪每一個 a link，整合網頁內文
for index, obj in enumerate(list_posts):
    res_ = req.get(obj['link'])
    soup_ = bs(res_.text, "lxml")

    # 去掉 div.article-metalline (作者、標題、時間...等)
    for div in soup_.select('div[class^="article-metalline"]'):
        div.decompose()

    # 去掉 div.push (推文：推、→、噓) (判斷去掉元素是否存在)
    if len(soup_.select('div.push')) > 0:
        for div in soup_.select('div.push'):
            div.decompose()

```



```
# 取得實際需要的內容 (類似 JavaScript 的 innerHTML)
html = soup_.select_one('div#main-content').decode_contents()

# 整合到列表資訊的變數當中
list_posts[index]['html'] = html

# 預覽所有結果
pprint(list_posts)
```

Module 10. 套件 Selenium (一)

解析 Selenium 、 WebDriver 與 Browser 連動關係

- Selenium 是一種 web automatic testing 工具 (套件) , 藉此操作 WebDriver , 協助開發者操作網頁表單資料、點選按鈕或連結、取得網頁內容並進行檢驗。
- WebDriver 是用來執行並操作瀏覽器的一個 API 介面 , 程式透過呼叫 WebDriver 來直接對瀏覽器進行操作 , 實作則決定於所選用的瀏覽器 driver , 例如有 ChromeDriver, EdgeDriver, FirefoxDriver 等。
- Browser 經由 WebDriver 啟動 , 讓 Selenium 進行操作 , 完成網頁自動化的工作。

方法	說明
<code>get_window_position()</code>	取得瀏覽器視窗左上角位置
<code>set_window_position(x, y)</code>	設定瀏覽器視窗左上角位置
<code>get_window_size()</code>	取得瀏覽器視窗大小
<code>set_window_size(x, y)</code>	設定瀏覽器視窗大小
<code>maximize_window()</code>	將瀏覽器視窗最大化
<code>minimize_window()</code>	將瀏覽器視窗最小化

圖：還操控瀏覽器的位置與大小

屬性	說明
name	瀏覽器名稱
title	目前開啟網頁之標題
current_url	目前開啟網頁之 URL
page_source	目前開啟網頁之原始碼
session_id	網頁連線 id
capabilities	瀏覽器功能設定

圖：driver.page_source 外，還有其它可以使用

selenium 套件

'''

參考網頁：

[1] 下載 Chrome Web Driver

<https://chromedriver.chromium.org/downloads>

'''

操作 browser 的 API

from selenium.webdriver.chrome.service import Service

from selenium import webdriver

匯入套件

from bs4 import BeautifulSoup as bs

強制等待（執行期間休息一下）

from time import sleep

使用 Chrome 的 WebDriver

my_service = Service(executable_path="./chromedriver.exe")

driver = webdriver.Chrome(service=my_service)

'''

補充：若沒有特別設定，只要電腦有安裝 Chrome，就可以直接使用

driver = webdriver.Chrome()

```
'''

# 開啟 104 人力行銀 首頁
driver.get("https://www.104.com.tw/jobs/main/")

# 取得檢視原始碼的內容 (page_source 取得的 html，是動態的、使用者操作過後的結果)
html = driver.page_source

# 印出 html (也可以跟 BeautifulSoup 整合)
# print(html)

# 指定 lxml 作為解析器
soup = bs(html, "lxml")

# 取得元素
div = soup.select_one('div.job-search-content_link')

# 顯示內文
print(div.get_text())

# 休眠幾秒
sleep(3)

# 關閉瀏覽器
driver.quit()
```

Module 11. 套件 Selenium (二)

如何查找頁面元素 (ID / Class / Tag / CSS Selector / ...)

註: 新的 webdriver 版本已不支援 `find_element(s)_by_xxx()` 系列的語法

方法	說明
<code>find_element(by, value)</code>	使用 <code>by</code> 指定之方法取得第一個符合 <code>value</code> 的元素
<code>find_elements(by, value)</code>	使用 <code>by</code> 指定之方法取得所有符合 <code>value</code> 的元素
<code>find_element_by_class_name(name)</code>	傳回符合指定 <code>class</code> 名稱之元素
<code>find_elements_by_class_name(name)</code>	傳回符合指定 <code>class</code> 名稱之元素串列
<code>find_element_by_css_selector(selector)</code>	傳回符合指定 <code>CSS</code> 選擇器名稱之元素
<code>find_elements_by_css_selector(selector)</code>	傳回符合指定 <code>CSS</code> 選擇器名稱之元素串列
<code>find_element_by_id(id)</code>	傳回符合指定 <code>id</code> 之元素
<code>find_elements_by_id(id)</code>	傳回符合指定 <code>id</code> 之元素串列
<code>find_element_by_link_text(text)</code>	傳回符合指定超連結文字之元素
<code>find_elements_by_link_text(text)</code>	傳回符合指定超連結文字之元素串列
<code>find_element_by_partial_link_text(text)</code>	傳回符合部分指定超連結文字之元素
<code>find_elements_by_partial_link_text(text)</code>	傳回符合部分指定超連結文字之元素串列
<code>find_element_by_name(name)</code>	傳回符合指定元素名稱之元素
<code>find_elements_by_name(name)</code>	傳回符合指定元素名稱之元素串列
<code>find_element_by_tag_name(tag)</code>	傳回符合指定標籤名稱之元素
<code>find_elements_by_tag_name(tag)</code>	傳回符合指定標籤名稱之元素串列

圖：取得網頁元素方法

匯入自動測試工具相關套件

...

匯入套件

...

操作 `browser` 的 `API`

```
from selenium.webdriver.chrome.service import Service
from selenium import webdriver
```

```

# 處理逾時例外的工具

from selenium.common.exceptions import TimeoutException

# 面對動態網頁，等待某個元素出現的工具，通常與 expected_conditions 搭配

from selenium.webdriver.support.ui import WebDriverWait

# 搭配 WebDriverWait 使用，對元素狀態的一種期待條件，若條件發生，則等待結
束，往下一行執行

from selenium.webdriver.support import expected_conditions as EC

# 期待元素出現要透過什麼方式指定，通常與 EC、WebDriverWait 一起使用

from selenium.webdriver.common.by import By

# 強制等待（執行期間休息一下）

from time import sleep

# 整理 json 使用的工具

import json

# 執行 command 的時候用的

import os

...

selenium 啟動 Chrome 的進階配置參數

參考網址：https://stackoverflow.max-everyday.com/2019/12/selenium-chrome-options/

...

```

```

# 啟動瀏覽器工具的選項

my_options = webdriver.ChromeOptions()
# my_options.add_argument("--headless")           #不開啟實體瀏覽器背景執行
my_options.add_argument("--start-maximized")      #最大化視窗
my_options.add_argument("--incognito")           #開啟無痕模式
my_options.add_argument("--disable-popup-blocking") #禁用彈出攔截
my_options.add_argument("--disable-notifications") #取消 chrome 推播通知
my_options.add_argument("--lang=zh-TW")          #設定為正體中文


# 使用 Chrome 的 WebDriver

my_service = Service(executable_path="./chromedriver.exe")
driver = webdriver.Chrome(
    options = my_options,
    service = my_service
)

```

在瀏覽器中執行自訂 JavaScript 程式

```

# 開啟網頁
driver.get("http://crptransfer.moe.gov.tw/")

# 跳出 alert 視窗 (在 chrome 裡面執行 javascript 語法)
driver.execute_script("window.alert('這是我們自訂的彈跳視窗');")

# 等個幾秒
sleep(3)

# 點選彈出裡面的確定按鈕
driver.switch_to.alert.accept()

```

輸入文字，送出表單

```

# 開啟網頁

```

```
driver.get("http://crptransfer.moe.gov.tw/")

# 尋找網頁中的搜尋框
inputElement = driver.find_element(By.CSS_SELECTOR, 'input#SN')

# 在搜尋框中輸入文字
inputElement.send_keys("人帥真好")

# 睡個幾秒
sleep(2)

# 送出搜尋
inputElement.submit()

# 搜尋結果的 CSS Selector
cssSelector = "body > table > tbody > tr:nth-child(1) > td > main >
article > div > table > tbody > tr:nth-child(2) > td"

try:
    # 等待網頁搜尋結果
    WebDriverWait(driver, 10).until(
        EC.presence_of_element_located(
            (By.CSS_SELECTOR, cssSelector)
        )
    )

    # 取得第一頁搜尋結果
    element = driver.find_element(By.CSS_SELECTOR, cssSelector)

    # 輸出想要爬取的文字
    print(element.text)
    print(element.get_attribute('innerText')) # 另一種寫法

    # 睡個幾秒
    sleep(3)
except TimeoutException:
    print('等待逾時！')
```


輸入文字，按下送出鈕

```
# 開啟網頁
driver.get("https://www.104.com.tw/jobs/main/")

# 尋找網頁中的搜尋框
inputElement = driver.find_element(By.CSS_SELECTOR, 'input#ikeyword')

# 在搜尋框中輸入文字
inputElement.send_keys("python")

# 睡個幾秒
sleep(2)

# 按鈕選擇器
cssSelectorBtn = "button.btn.btn-primary.js-formCheck"

try:
    # 等待元素
    WebDriverWait(driver, 10).until(
        EC.presence_of_element_located(
            (By.CSS_SELECTOR, cssSelectorBtn)
        )
    )

    # 取得按鈕元素
    btn = driver.find_element(By.CSS_SELECTOR, cssSelectorBtn)

    # 按下按鈕
    btn.click()

    # 睡個幾秒
    sleep(3)
except TimeoutException:
    print('等待逾時！')
```

刷新頁面 (類似 F5 或 Ctrl + R)

開啟網頁

```
driver.get("https://reurl.cc/jR725D")
```

睡個幾秒

```
sleep(3)
```

刷新頁面

```
driver.refresh()
```

睡個幾秒

```
sleep(3)
```

刷新頁面

```
driver.refresh()
```

關閉瀏覽器

關閉瀏覽器

```
driver.quit()
```

Module 12. 套件 Selenium (三)

等待 (WebDriverWait)

等待有分幾種：

- 強制等待
 - 通常泛指 `sleep()` 函式
- 隱性等待 (`implicitly_wait`)
 - 設置了一個最長等待時間，如果在規定時間內網頁加載完成，或是能夠取得指定的元素 (透過 `find_element*`)，則執行下一步，否則一直等到時間截止，然後拋出例外。
- 顯性等待 (`WebDriverWait`)
 - 配合 `until()` 和 `until_not()` 方法，就能夠根據判斷條件而進行靈活地等待了。它主要的意思就是：如果條件成立了，則執行下一步，否則繼續等待，直到超過設置的最長時間，直到拋出 `TimeoutException`。

期待狀況/條件 (Expected Condition)

通常與 `WebDriverWait` 配合使用，動態等待頁面上元素出現或者消失。

- `title_is`
 - 判斷當前頁面的 `title` 是否精確等於預期

- title_contains
 - 判斷當前頁面的 title 是否包含預期字符串
- presence_of_element_located
 - 判斷某個元素是否被加到了 dom 樹裡，並不代表該元素一定可見
- visibility_of_element_located
 - 判斷元素是否可見，可見代表元素非隱藏，並且元素的寬和高都不等於 0
- presence_of_all_elements_located
 - 判斷是否至少有 1 個元素存在於 DOM tree 中。舉個例子，如果頁面上有 n 個元素的 class 都是 'col-md-3'，那麼只要有 1 個元素存在，這個方法就返回 True
- text_to_be_present_in_element
 - 判斷某個元素中的 text 是否包含了預期的字串
- text_to_be_present_in_element_value
 - 判斷某個元素中的 value 屬性是否包含了預期的字串
- frame_to_be_available_and_switch_to_it
 - 判斷該 frame 是否可以 switch 進去，如果可以的話，返回 True 並且 switch 進去，否則返回 False
- invisibility_of_element_located
 - 判斷某個元素中是否不存在於 DOM tree 或不可見
- element_to_be_clickable
 - 判斷某個元素中是否可見並且是 enable 的，這樣的話才叫 clickable
- staleness_of
 - 等某個元素從 dom 樹中移除，注意，這個方法也是返回 True 或 False
- element_to_be_selected
 - 判斷某個元素是否被選中了，一般用在下拉列表
- element_selection_state_to_be
 - 判斷某個元素的選中狀態是否符合預期
- element_located_selection_state_to_be
 - 跟上面的方法作用一樣，只是上面的方法傳入定位到的 element，而這個方法傳入 locator
- alert_is_present
 - 判斷頁面上是否存在 alert，這是個老問題，很多同學會問到

元素定位策略/方式 (By)

- By.ID = "id"
- By.CSS_SELECTOR = "css selector"
- By.XPATH = "xpath"
- By.LINK_TEXT = "link text"
- By.PARTIAL_LINK_TEXT = "partial link text"
- By.NAME = "name"
- By.TAG_NAME = "tag name"
- By.CLASS_NAME = "class name"

匯入自動測試工具相關套件

'''

參考網址:

[1] Webdriver Manager for Python

<https://pypi.org/project/webdriver-manager/>

'''

匯入套件

```
from selenium import webdriver
from selenium.webdriver.chrome.service import Service
from webdriver_manager.chrome import ChromeDriverManager
from selenium.common.exceptions import TimeoutException,
NoSuchElementException
from selenium.webdriver.support.ui import WebDriverWait
from selenium.webdriver.support import expected_conditions as EC
from selenium.webdriver.common.by import By
from time import sleep
```

強制等待

```

'''
強制等待
'''
# 開啟用於自動控制的瀏覽器（自動取得 Chrome 的 WebDriver）
driver = webdriver.Chrome(
    service = Service(ChromeDriverManager().install())
)

try:
    # 走訪網址
    driver.get('https://tw.yahoo.com/')

    # 強制等待 3 秒
    sleep(3)

    # 印出網址
    print(driver.current_url)
except:
    print("程式出錯!")
finally:
    # 關閉瀏覽器
    driver.quit()

```

隱性等待

```

'''
隱性等待
'''
# 開啟用於自動控制的瀏覽器
driver = webdriver.Chrome()

try:
    # 最多等 15 秒
    driver.implicitly_wait(15)

    # 走訪網址

```

```

driver.get('https://tw.yahoo.com/')

# 取得元素
element = driver.find_element(By.CSS_SELECTOR, 'a#header-logo')

# 印出超連結 ( 透過 .get_attribute('屬性') 來取得屬性的值 )
print(element.get_attribute('href'))
except NoSuchElementException:
    print("找不到元素!")
finally:
    # 關閉瀏覽器
    driver.quit()

```

顯性等待

```

'''
顯性等待
'''
# 開啟用於自動控制的瀏覽器
driver = webdriver.Chrome()

try:
    # 走訪網址
    driver.get('https://www.youtube.com/?gl=TW')

    # 滿足條件（10 秒內找到元素），則往下一步
    WebDriverWait(driver, 10).until(
        EC.presence_of_element_located(
            (By.LINK_TEXT, '首頁')
        )
    )

    # 印出首頁連結
    print(driver.find_element(By.LINK_TEXT, '首頁')
        .get_attribute('href'))

```

```
except TimeoutException:  
    print('等待逾時！')  
finally:  
    # 關閉瀏覽器  
    driver.quit()
```


Module 13. ActionChains

匯入工具

加入行為鍊 `ActionChains` (在 `WebDriver` 中模擬滑鼠移動、點擊、拖曳、按右鍵出現選單，以及鍵盤輸入文字、按下鍵盤上的按鈕等)

```
from selenium.webdriver.common.action_chains import ActionChains
```

基本用法

方法	說明
<code>click(on_element=None)</code>	單擊滑鼠左鍵
<code>click_and_hold(on_element=None)</code>	點選滑鼠左鍵，不鬆開
<code>context_click(on_element=None)</code>	點選滑鼠右鍵
<code>double_click(on_element=None)</code>	雙擊滑鼠左鍵
<code>drag_and_drop(source, target)</code>	拖拽到某個「元素」然後鬆開
<code>drag_and_drop_by_offset(source, xoffset, yoffset)</code>	拖拽到某個「座標」然後鬆開
<code>key_down(value, element=None)</code>	按下某個鍵盤上的鍵
<code>key_up(value, element=None)</code>	鬆開某個鍵
<code>move_by_offset(xoffset, yoffset)</code>	滑鼠從當前位置移動到某個座標
<code>move_to_element(to_element)</code>	滑鼠移動到某個元素
<code>move_to_element_with_offset(to_element, xoffset, yoffset)</code>	移動到距某個元素（左上角座標）多少距離的位置
<code>pause(seconds)</code>	暫停動作一段時間
<code>perform()</code>	執行鏈中的所有動作
<code>release(on_element=None)</code>	在某個元素位置鬆開滑鼠左鍵
<code>send_keys(keys_to_send)</code>	傳送某個鍵到當前焦點的元素
<code>send_keys_to_element(element, keys_to_send)</code>	傳送某個鍵到指定元素

寫法

- 鍊式

```
ActionChains(driver).move_to_element( web_element ).click( web_element ).perform()
```

或是

```
action_chains = ActionChains(driver)
```

```
action_chains.move_to_element( web_element ).click( web_element ).perform()
```

- 分步

```
action_chains = ActionChains(driver)
```

```
action_chains.move_to_element( web_element )
```

```
action_chains.click( web_element )
```

```
action_chains.perform()
```

補充: 切換目前到 iframe 當中

- 取得網頁上的 iframe

```
iframe = driver.find_element(By.CSS_SELECTOR, "iframe#game-iframe")
```

- 切換到 iframe 當中

```
driver.switch_to.frame(iframe)
```

- 回到主框架

```
driver.switch_to.default_content()
```

參考連結

1. Selenium 的 ActionChains Api 介面詳解

<https://www.796t.com/article.php?id=325399>

2. python selenium 滑鼠鍵盤操作 (ActionChains)

<https://www.796t.com/article.php?id=94198>

3. 行為鏈

https://python-selenium-zh.readthedocs.io/zh_CN/latest/7.2%E8%A1%8C%E4%B8%BA%E9%93%BE/

4. ActionChains In Selenium

<https://medium.com/@kavidhanda/actionchains-in-selenium-cde43dee0111>

5. Selenium 4.1.0 documentation - selenium.webdriver.common.action_chains

https://www.selenium.dev/selenium/docs/api/py/webdriver/selenium.webdriver.common.action_chains.html

匯入工具

'''

匯入工具

備註：每次執行以下任一範例前，都要執行一次"匯入工具"的 cell

'''

操作 browser 的 API

from selenium import webdriver

from selenium.webdriver.chrome.service import Service

from webdriver_manager.chrome import ChromeDriverManager

期待元素出現要透過什麼方式指定，通常與 EC、WebDriverWait 一起使用

from selenium.webdriver.common.by import By

加入行為鍊 ActionChain (在 WebDriver 中模擬滑鼠移動、點擊、拖曳、按右鍵出現選單，以及鍵盤輸入文字、按下鍵盤上的按鈕等)

from selenium.webdriver.common.action_chains import ActionChains

加入鍵盤功能 (例如 Ctrl、Alt 等)

from selenium.webdriver.common.keys import Keys

強制等待 (執行期間休息一下)

```

from time import sleep

# 啟動瀏覽器工具的選項
my_options = webdriver.ChromeOptions()
# my_options.add_argument("--headless") #不開啟實體瀏覽器
# 背景執行
my_options.add_argument("--start-maximized") #最大化視窗
my_options.add_argument("--incognito") #開啟無痕模式
my_options.add_argument("--disable-popup-blocking") #禁用彈出攔截
my_options.add_argument("--disable-notifications") #取消通知

# 使用 Chrome 的 WebDriver
driver = webdriver.Chrome(
    options = my_options
)

```

範例 1: 對特定座標連續點擊

...

範例 1: 對特定座標連續點擊

補充:

先在 **console** 面版中，輸入下列程式碼，
會在滑鼠一次移動後，顯示座標。

```

document.onmousemove = function(e){
    var x = e.pageX;
    var y = e.pageY;
    e.target.title = "X is "+x+" and Y is "+y;
};

```

參考連結:

[1] Pop Cat

<https://popcat.click/>

[2] Is there a way to tell Chrome web debugger to show the current mouse position in page coordinates?

<https://stackoverflow.com/questions/12888584/is-there-a-way-to-tell-chrome-web-debugger-to-show-the-current-mouse-position-in>

...

前往頁面

```
driver.get('https://popcat.click/')
```

建立行為鍊

```
ac = ActionChains(driver)
```

移到指定座標

...

從 0,0 開始，若先前已移動，則進行相對位移，數值要用負號

例如 `ac.move_by_offset(-50, -80)`

...

```
ac.move_by_offset(870, 350)
```

暫停一下

```
ac.pause(3)
```

點擊一下

```
for i in range(2000):  
    ac.click()
```

執行

```
ac.perform()
```

睡一下

```
sleep(3)
```

關閉 web driver

```
driver.quit()
```

範例 2: 拖曳網頁元素 (使用 drag_and_drop)

'''

範例 2: 拖曳網頁元素

參考連結:

[1] Mootools Drag and Drop example

<http://sahitest.com/demo/dragDropMooTools.htm>

'''

前往頁面

```
driver.get('http://sahitest.com/demo/dragDropMooTools.htm')
```

取得被拖曳的來源元素

```
dragger = driver.find_element(By.CSS_SELECTOR, "div#dragger")
```

目標元素 (放置的區域, 共 4 個)

```
items = driver.find_elements(By.CSS_SELECTOR, "div.item")
```

建立行為鍊

```
ac = ActionChains(driver)
```

暫停一下

```
ac.pause(1)
```

放置第一個

```
ac.drag_and_drop(dragger, items[0])
```

暫停一下

```
ac.pause(1)
```

放置第二個

```
ac.click_and_hold(dragger).release(items[1])
```

暫停一下

```
ac.pause(1)
```

```
# 放置第三個
ac.click_and_hold(dragger).move_to_element(items[2]).release()

# 暫停一下
ac.pause(1)

# 放置第四個
ac.click_and_hold(dragger).move_by_offset(400, 150).release()

# 執行
ac.perform()

# 睡一下
sleep(3)

# 關閉 web driver
driver.quit()
```

範例 3: 組合熱鍵 (全選 + 複製 + 貼上)

```
'''
範例 3: 組合熱鍵 (全選 + 複製 + 貼上)

參考連結:
[1] Display Text Input Fields
https://www.w3schools.com/tags/tryit.asp?filename=tryhtml5\_input\_type\_text
'''

# 前往頁面
driver.get('https://www.w3schools.com/tags/tryit.asp?filename=tryhtml5_input_type_text')

# 取得網頁上的 iframe
iframe = driver.find_element(By.CSS_SELECTOR, "iframe#iframeResult")
```

```
# 切換到 iframe 當中
driver.switch_to.frame(iframe)

# # 回到主框頁
# driver.switch_to.default_content()

# 取得第一個文字欄位
inputText01 = driver.find_element(By.CSS_SELECTOR, "input#fname")

# 取得第二個文字欄位
inputText02 = driver.find_element(By.CSS_SELECTOR, "input#lname")

# 建立行為鍊
ac = ActionChains(driver)

# 在第一個文字欄位當中輸入萬用字元
ac.key_down(Keys.SHIFT,
inputText01).send_keys('12345').key_up(Keys.SHIFT).send_keys('67890')

# 暫停一下
ac.pause(1)

# 全選與複製第一個文字欄位當中的所有字元
ac.key_down(Keys.CONTROL,
inputText01).send_keys('ac').key_up(Keys.CONTROL)

# 暫停一下
ac.pause(1)

# 在第二個文字欄位當中貼上文字
ac.key_down(Keys.CONTROL,
inputText02).send_keys('v').key_up(Keys.CONTROL)

# 執行
ac.perform()

# 睡一下
```



```
sleep(3)

# 關閉 web driver
driver.quit()
```

範例 4: 移動 Slider (by a handle)

```
'''
範例 4: 移動 Slider (by a handle)

參考連結:
[1] jQuery UI - Slider
https://jqueryui.com/slider/
'''

# 前往頁面
driver.get('https://jqueryui.com/slider/')

# 取得網頁上的 iframe
iframe = driver.find_element(By.CSS_SELECTOR, "iframe.demo-frame")

# 切換到 iframe 當中
driver.switch_to.frame(iframe)

# 拿到把手元素
span = driver.find_element(By.CSS_SELECTOR, 'span.ui-slider-handle.ui-corner-all.ui-state-default')

# 建立行為鍊
ac = ActionChains(driver)

# 暫停
ac.pause(1)

# 點住不放，並向右移動，移到指定的座標（註：目前在 iframe 當中，使用的座標是
iframe 內部座標）
```

```
# 註：點住移動，只能在 iframe 範圍內，超出的話，span 會放不掉
ac.click_and_hold(span).move_by_offset(577, 16).release()

# 執行
ac.perform()

# 睡一下
sleep(5)

# 關閉 web driver
driver.quit()
```

Module 14. PyAutoGUI

控制電腦的鍵盤、滑鼠，對圖形化介面進行操作的工具

安裝套件

一般安裝

```
pip install pyautogui
```

影像處理

```
pip install opencv-python
```

```
pip install opencv-contrib-python
```

Optional: 有影像處理的需求，則需要安裝 [OpenCV](#)

使用方法

- 滑鼠功能

方法	說明
<code>pyautogui.position()</code>	取得滑鼠游標座標
<code>pyautogui.size()</code>	目前螢幕大小
<code>pyautogui.onScreen(x, y)</code>	判斷游標座標是否在螢幕範圍內
<code>pyautogui.PAUSE = 2.5</code>	設定 PyAutoGUI 每一個動作間隔 2.5 秒

方法	說明
<code>pyautogui.moveTo(x, y, duration=num_seconds)</code>	移動滑鼠游標到 <code>x,y</code>
<code>pyautogui.moveRel(xOffset, yOffset, duration=num_seconds)</code>	在目前游標座標偏移相對位置
<code>pyautogui.dragTo(x, y, duration=num_seconds, button='left')</code>	按住滑鼠左鍵・拖曳滑鼠到 <code>x,y</code>
<code>pyautogui.dragRel(xOffset, yOffset, duration=num_seconds, button='left')</code>	按住滑鼠左鍵・在目前游標座標拖曳滑鼠到相對位置
<code>pyautogui.click(x=moveToX, y=moveToY, clicks=num_of_clicks, interval=secs_between_clicks, button='left')</code>	點繫滑鼠
<code>pyautogui.rightClick(x=moveToX, y=moveToY)</code>	在指定座標按下滑鼠右鍵
<code>pyautogui.middleClick(x=moveToX, y=moveToY)</code>	在指定座標按下滑鼠中間鍵
<code>pyautogui.doubleClick(x=moveToX, y=moveToY)</code>	在指定座標連點兩下滑鼠左鍵
<code>pyautogui.tripleClick(x=moveToX, y=moveToY)</code>	在指定座標連點三下滑鼠左鍵
<code>pyautogui.scroll(amount_to_scroll, x=moveToX, y=moveToY)</code>	滑鼠游標移到 <code>x,y</code> ・而後滾動 <code>amount_to_scroll</code> 次; 正值向上・負值向下
<code>pyautogui.mouseDown(x=moveToX, y=moveToY, button='left')</code>	在指定座標按下滑鼠按鍵
<code>pyautogui.mouseUp(x=moveToX, y=moveToY, button='left')</code>	在指定座標放開滑鼠按鍵

- 鍵盤功能

方法	說明
<code>pyautogui.typewrite('Hello world!\n', interval=secs_between_keys)</code>	在游標所在位置輸入文字
<code>pyautogui.typewrite(['a', 'b', 'c', 'left', 'backspace', 'enter', 'f1'], interval=secs_between_keys)</code>	在游標所在位置分別輸入鍵盤按鍵
<code>pyautogui.write('Hello world!', interval=0.25)</code>	每 0.25 秒輸入一次文字，但要先 手動將焦點移到文字欄位當中
<code>pyautogui.hotkey('ctrl', 'c')</code>	組合鍵 <code>ctrl + c</code> (複製)
<code>pyautogui.hotkey('ctrl', 'v')</code>	組合鍵 <code>ctrl + v</code> (貼上)
<code>pyautogui.hotkey('ctrl', 'alt', 'delete')</code>	組合鍵 <code>ctrl + alt + delete</code>
<code>pyautogui.keyDown(key_name)</code>	按下指定鍵
<code>pyautogui.keyUp(key_name)</code>	放開指定鍵
<code>pyautogui.press('enter')</code>	按下 <code>enter</code>

- 訊息框功能

方法	說明
<code>pyautogui.alert('This displays some text with an OK button.')</code>	警示訊息

方法	說明
<code>pyautogui.confirm('This displays text and has an OK and Cancel button.')</code>	確認訊息 (會回傳值)
<code>pyautogui.prompt('This lets the user type in a string and press OK.')</code>	提示訊息 (會回傳值)

- 截圖功能

方法	說明
<code>pyautogui.screenshot()</code>	回傳 Pillow or PIL Image 物件
<code>pyautogui.screenshot('foo.png')</code>	回傳 Pillow or PIL Image 物件，並儲存檔案
<code>pyautogui.locateOnScreen('looksLikeThis.png')</code>	若畫面上有跟照片相同的圖案，回傳它的 Pillow or PIL Image 物件，並顯示它的 x,y
<code>pyautogui.locateAllOnScreen('looksLikeThis.png')</code>	若畫面上有跟照片相同的圖案，回傳它的 Pillow or PIL Image 物，此方法會回傳全部圖片的 left, top, width, height
<code>pyautogui.locateCenterOnScreen('looksLikeThis.png')</code>	若畫面上有跟照片相同的圖案，則取得該圖案在螢幕當中的中心點座標
<code>pyautogui.center(pyautogui.locateOnScreen('looksLikeThis.png'))</code>	取得 Pillow or PIL Image 物件的中心點座標

鍵盤表 (key_name 名稱)

```
[ '\t', '\n', '\r', ' ', '!', '"', '#', '$', '%', '&', "'", '(', ')', '*', '+', ',', '-', '.', '/', '0', '1', '2', '3', '4', '5', '6', '7', '8', '9', ':', ';', '<', '=', '>', '?', '@
```

```
' , '[' , '\\ ' , ']' , '^' , '_' , '`' , 'a' , 'b' , 'c' , 'd' , 'e' , 'f' , 'g' , 'h' , 'i' , 'j' , 'k' , 'l' , 'm' , 'n' , 'o' , 'p' , 'q' , 'r' , 's' , 't' , 'u' , 'v' , 'w' , 'x' , 'y' , 'z' , '{' , '|' , '}' , '~' , 'accept' , 'add' , 'alt' , 'altleft' , 'altright' , 'apps' , 'backspace' , 'browserback' , 'browserfavorites' , 'browserforward' , 'browserhome' , 'browserrefresh' , 'browsersearch' , 'browserstop' , 'capslock' , 'clear' , 'convert' , 'ctrl' , 'ctrlleft' , 'ctrlright' , 'decimal' , 'del' , 'delete' , 'divide' , 'down' , 'end' , 'enter' , 'esc' , 'escape' , 'execute' , 'f1' , 'f10' , 'f11' , 'f12' , 'f13' , 'f14' , 'f15' , 'f16' , 'f17' , 'f18' , 'f19' , 'f2' , 'f20' , 'f21' , 'f22' , 'f23' , 'f24' , 'f3' , 'f4' , 'f5' , 'f6' , 'f7' , 'f8' , 'f9' , 'final' , 'fn' , 'hanguel' , 'hangul' , 'hanja' , 'help' , 'home' , 'insert' , 'junja' , 'kana' , 'kanji' , 'launchapp1' , 'launchapp2' , 'launchmail' , 'launchmediaselect' , 'left' , 'modechange' , 'multiply' , 'nexttrack' , 'nonconvert' , 'num0' , 'num1' , 'num2' , 'num3' , 'num4' , 'num5' , 'num6' , 'num7' , 'num8' , 'num9' , 'numlock' , 'pagedown' , 'pageup' , 'pause' , 'pgdn' , 'pgup' , 'playpause' , 'prevtrack' , 'print' , 'printscreen' , 'prntscrn' , 'prtsc' , 'prtscr' , 'return' , 'right' , 'scrolllock' , 'select' , 'separator' , 'shift' , 'shiftleft' , 'shiftright' , 'sleep' , 'space' , 'stop' , 'subtract' , 'tab' , 'up' , 'volumedown' , 'volumemute' , 'volumeup' , 'win' , 'winleft' , 'winright' , 'yen' , 'command' , 'option' , 'optionleft' , 'optionright' ]
```

參考網頁

[1] Welcome to PyAutoGUI's documentation!

<https://pyautogui.readthedocs.io/en/latest/index.html>

[2] PyAutoGUI - Installation

<https://pyautogui.readthedocs.io/en/latest/install.html>

[3] Python：用 PyAutoGUI 來操控滑鼠及鍵盤

<https://yang10001.yia.app/wp/2021/03/06/python-%E7%94%A8-pyautogui-%E4%BE%86%E6%93%8D%E6%8E%A7%E6%BB%91%E9%BC%A0%E5%8F%8A%E9%8D%B5%E7%9B%A4/>

[4] Python 自動化工具 – PyAutoGUI 釋放你的雙手

<http://13.231.129.69/2020/08/13/python-%E8%87%AA%E5%8B%95%E5%8C%96%E5%B7%A5%E5%85%B7-pyautogui-%E9%87%8B%E6%94%BE%E4%BD%A0%E7%9A%84%E9%9B%99%E6%89%8B/>

[5] PyAutoGUI：使用 Python 控制電腦

<https://yanwei-liu.medium.com/pyautogui-%E4%BD%BF%E7%94%A8python%E6%93%8D%E6%8E%A7%E9%9B%BB%E8%85%A6-662cc3b18b80>

[5] 【PYTHON】pyautogui 如何增加每秒的點選次數？

<https://www.796t.com/post/ZTVueDA=.html>

[6] pyautogui 文檔 (五)：截圖及定位功能

<https://www.itread01.com/content/1556528332.html>

參考網頁

[1] GitHub: keyboard

<https://github.com/boppreh/keyboard>

[2] GitHub: mouse

<https://github.com/boppreh/mouse>

安裝套件

...

安裝套件

...

`!pip install pyautogui opencv-python opencv-contrib-python keyboard`

匯入工具

```
'''  
匯入工具  
'''  
  
import pyautogui  
from time import sleep, time  
import keyboard  
from IPython.display import clear_output
```

協助了解滑鼠游標定位

```
'''  
請在 Terminal 當中執行  
取得滑鼠座標和游標上的色碼，協助我們定位  
補充：必須在 Terminal 當中執行，請見 18.py  
'''  
  
pyautogui.displayMousePosition()
```

取得目前滑鼠座標

```
'''  
取得目前滑鼠座標  
'''  
  
while True:  
    #自動清除此格的文字輸出  
    clear_output(wait=True)  
  
    #取得滑鼠游標的座標，並加以輸出  
    x, y = pyautogui.position()  
    print(f"x={x}, y={y}")  
  
    # 睡一下，以免吃光記憶體  
    sleep(0.1)
```

記錄滑鼠軌跡

```
'''
記錄滑鼠軌跡
'''

# 記錄軌跡用的變數
listMove = []

# 記錄軌跡
def record():
    # 監聽事件
    while True:
        if keyboard.is_pressed('ctrl'): # 按下 Ctrl 錄製軌跡，放開就不進行錄製
            x, y = pyautogui.position()
            listMove.append(f"{x},{y}")
            sleep(0.01)
        elif keyboard.is_pressed('alt'): # 按下 alt，結束程式
            break

    # 寫入檔案
    with open("move.txt", "w", encoding="utf-8") as file:
        file.write( '\n'.join(listMove) )

'''
主程式
'''

if __name__ == "__main__":
    record()
```

讀取滑鼠軌跡，並模擬滑鼠游標移動

```
'''
讀取滑鼠軌跡，並模擬滑鼠游標移動
'''
```

```

'''
# 模擬移動
def move():
    # 讀取軌跡檔
    with open("move.txt", "r", encoding="utf-8") as file:
        # 逐行讀取
        for line in file:
            # 切割文字，找出 x,y
            x, y = line.strip().split(",")

            # 移動（設定移動時間）
            pyautogui.moveTo( int(x), int(y), duration=0.01)

            # 提前結束
            if keyboard.is_pressed('alt'):
                break

'''
主程式
'''
if __name__ == "__main__":
    move()

```

確認畫面上的圖片物件是否存在

```

'''
每秒判斷桌面上的圖片(座標)是否存在
補充：請先開小算盤(計算機)
'''
while True:
    # 睡一下
    sleep(0.1)

    #自動清除此格的文字輸出
    clear_output(wait=True)

```

```
# 取得 Box 物件
btn_2_location = pyautogui.locateOnScreen('images/2.png', confidence=0.9)

# 輸出
print(btn_2_location)
```

自動使用小算盤(計算機)

```
'''
自動使用計算機

補充：此時計算機應該明顯出現在桌面上，不然會有判斷錯誤的問題
'''

# 設定每一個動作，都暫停若干秒
pyautogui.PAUSE = 0.5

# 比對所有圖片，取得顯示在桌面的圖片物件 (pillow / PIL Image)
btn_0_location = pyautogui.locateOnScreen('images/0.png',
confidence=0.9)
btn_1_location = pyautogui.locateOnScreen('images/1.png',
confidence=0.9)
btn_2_location = pyautogui.locateOnScreen('images/2.png',
confidence=0.9)
btn_3_location = pyautogui.locateOnScreen('images/3.png',
confidence=0.9)
btn_4_location = pyautogui.locateOnScreen('images/4.png',
confidence=0.9)
btn_5_location = pyautogui.locateOnScreen('images/5.png',
confidence=0.9)

# 取得每一個圖片的中心點
btn_0_point = pyautogui.center(btn_0_location)
btn_1_point = pyautogui.center(btn_1_location)
btn_2_point = pyautogui.center(btn_2_location)
```

```
btn_3_point = pyautogui.center(btn_3_location)
btn_4_point = pyautogui.center(btn_4_location)
btn_5_point = pyautogui.center(btn_5_location)

# 按下 5201314
pyautogui.click(btn_5_point.x, btn_5_point.y)
pyautogui.click(btn_2_point.x, btn_2_point.y)
pyautogui.click(btn_0_point.x, btn_0_point.y)
pyautogui.click(btn_1_point.x, btn_1_point.y)
pyautogui.click(btn_3_point.x, btn_3_point.y)
pyautogui.click(btn_1_point.x, btn_1_point.y)
pyautogui.click(btn_4_point.x, btn_4_point.y)
```

打擊遊戲

```
'''
打擊遊戲 - 魔術鋼琴鏢
https://html5.gamedistribution.com/rvvASMiM/44fbc5e5c6e54ac9985d1c81f1fb8121/index.html
'''

# 設定每一個動作，都暫停若干秒
pyautogui.PAUSE = 0.1

# 打擊點
listPoint = [
    [620, 600],
    [720, 600],
    [820, 600],
    [920, 600]
]

# 點擊
def click():
    for _ in listPoint:
        # 取得指定打擊點的 RGB 值
```

```
coord = pyautogui.pixel( _[0], _[1] )

# coord[0] 代表 Red, coord[1] 代表 Green, coord[2] 代表 Blue
if coord[0] == 0 and coord[1] == 0:
    pyautogui.mouseDown(_[0], _[1])
    pyautogui.mouseUp(_[0], _[1])

#主程式區域
if __name__ == "__main__":
    while True:
        # 當我們按下 ctrl 鍵時，自動點擊，按下 alt 則結束迴圈
        if keyboard.is_pressed('ctrl'):
            click()
        elif keyboard.is_pressed('alt'):
            break
```